



Institut Supérieur des Études Technologiques de Mahdia

Département : Technologies de l'Informatique

Développement des Systèmes Informatiques — DSI3.2

Rapport de Projet de Fin d'Études

**Koda — Robot compagnon intelligent et émotionnel connecté,
pilote par une application cross-platform**

**Système Embarqué • Intelligence Artificielle • Application Mobile
Cross-Plateforme**

Réalisé par :

Oussema KARIA

Salahedin JENDOUBI

Encadré par :

M.Wahid BANOUR — (Encadrant)

M.Hamza SASSI (Encadrant Entreprise)

Organisme d'accueil : —

Période : Février 2026 – Juin 2026

Résumé

Ce rapport présente KODA, un système embarqué intelligent conçu pour être un assistant de vie et un ami virtuel doté de sa propre personnalité et nature. KODA est capable de répondre de manière réfléchie à n'importe quelle personne, de raisonner comme un être humain et de reconnaître les individus grâce à ses modes de sécurité et de configuration.

L'architecture du système repose sur plusieurs composants complémentaires : un système embarqué Raspberry Pi constituant le cœur physique du robot ; un moteur de workflows n8n formant le cerveau de KODA, responsable de la préparation et de la réflexion des réponses ; une couche de services Python agissant comme distributeur universel, assurant la communication entre n8n, la base de données, l'application mobile et le Raspberry Pi tout en exposant les endpoints de tout l'écosystème ; une application mobile cross-plateforme pour la configuration et le suivi de vie du robot ; et une base de données persistante servant de mémoire à KODA.

Mots-clés : Système Embarqué, Assistant Virtuel, Raspberry Pi, n8n, Python, Cross-Plateforme, Intelligence Artificielle, Assistant de Vie, KODA.

DÉDICACE

Je dédie ce travail à ma famille, pilier silencieux de ma force et source inépuisable de soutien.

*Merci pour vos sacrifices immenses et pour avoir cru en moi tout au long de mon parcours
académique.*

*À mes parents, pour leur amour inconditionnel, leurs encouragements et leurs prières qui ont été la
lumière guidant chacun de mes pas. Ce succès est le vôtre autant que le mien.*

*À mes amis et collègues, pour leur soutien moral et pour avoir partagé avec moi cette aventure
inoubliable.*

*À mon binôme Salahedin, pour sa persévérance, sa créativité et sa complicité tout au long de ce
projet.*

*À tous ceux qui ont contribué, même par un simple mot d'encouragement, à l'accomplissement de
ce travail.*

Oussema KARIA

DÉDICACE

À ma famille,
pour son soutien inconditionnel et ses sacrifices immenses
tout au long de mon parcours académique.

À mon binôme Oussema, pour son enthousiasme, sa rigueur
et sa précieuse collaboration dans la réalisation de ce projet.

À mes encadrants,
pour leur guidance, leur patience et leur expertise technique.

Salahedin JENDOUBI

Remerciements

À notre encadrant académique, M. Wahid Banour,

nous adressons nos remerciements les plus sincères pour la qualité de l'accompagnement pédagogique, la disponibilité dont il a fait preuve à chaque étape, ainsi que pour ses conseils exigeants qui ont permis de structurer notre démarche et de renforcer la rigueur scientifique et technique de ce travail.

À notre encadrant en entreprise, M. Hamza Sassi,

nous exprimons toute notre gratitude pour l'accueil au sein de l'organisme d'accueil, pour le temps accordé aux échanges techniques et pour les orientations concrètes qui ont éclairé nos choix d'architecture et d'intégration tout au long du projet.

À la direction et à l'ensemble du corps enseignant de l'ISET de Mahdia,

et en particulier au département *Développement des systèmes informatiques* (DSI), nous témoignons notre reconnaissance pour la formation dispensée, pour l'exigence professionnelle transmise et pour l'environnement d'apprentissage qui a rendu possible la réalisation de ce projet de fin d'études.

À nos proches, amis et camarades,

nous disons merci pour la patience, les encouragements et la confiance manifestés durant cette période intensive ; leur soutien moral a compté autant que le travail collectif mené au sein du binôme.

Nous saluons enfin toute personne ayant contribué, directement ou indirectement, à l'aboutissement de ce rapport.

Oussema Karia

Salahedin Jendoubi

SOMMAIRE

Introduction Générale	1
I Cadre Général du Projet et Présentation de l'Organisme	2
I.1 Introduction du chapitre	3
I.2 Contexte Général du Projet	3
I.3 Présentation de l'Organisme d'Accueil (MicroEdition)	3
I.3.1 Profil de l'Entreprise	3
I.3.2 Services	4
I.3.3 Recherche & Développement (R&D)	4
I.3.4 Structure Organisationnelle	4
I.4 Problématique	5
I.5 Analyse des Solutions Existantes	5
I.5.1 Étude de l'existant	6
I.5.2 Synthèse et Critique : Le "Manque d'Humanité"	6
I.5.3 La Différenciation de Koda	7
I.6 Solution Proposée	7
I.7 Méthodologie du Projet	8
I.7.1 Modèle en spirale	8
I.8 Conclusion	8
II Préparation du Projet	11
II.1 Introduction du chapitre	12
II.2 Spécification des besoins	12
II.2.1 Spécifications des besoins fonctionnels	12
II.2.2 Spécification des besoins non fonctionnels	13
II.2.3 Architecture du système	14
II.2.4 Identification des acteurs	15
II.3 Pilotage du projet — Modèle en spirale et cycles de développement	17
II.3.1 Équipe et rôles	17

II.3.2	Découpage du travail : six cycles	17
II.4	Planification des cycles	19
II.5	Architecture	19
II.5.1	Architecture de l'application	19
II.5.1.1	Architecture en oignon (<i>Onion Architecture</i>) du backend	19
II.6	Environnement de Developement	20
II.6.1	Environnement matériel	20
II.7	Environnement logiciel	20
II.7.1	Outils de développement et modélisation	20
II.7.2	Langages et frameworks utilisés	21
II.8	Figures et diagrammes prévus pour ce chapitre	21
II.9	Conclusion	22
III	Cycle 1 : ANALYSEUR ET RÉFLEXION	23
III.1	Introduction	24
III.2	Fondements Théoriques	24
III.2.1	Que signifie « théorie du double traitement » ?	24
III.2.2	Réflexion rapide et réflexion lente	25
III.2.2.1	Réflexion rapide : réutiliser la mémoire déjà présente	25
III.2.2.2	Réflexion lente : analyser la mémoire pour fabriquer une réponse	25
III.2.3	Comment une question est comprise avant la réponse	25
III.2.4	Intérêt pour un compagnon conversationnel comme KODA	26
III.3	Définitions Fondamentales	26
III.3.1	Grand modèle de langage (LLM)	27
III.4	Modélisation globale du Cycle 1	27
III.4.1	Vue d'ensemble des trois flux n8n	28
III.4.2	Diagramme de cas d'utilisation général	29
III.4.3	Schéma de classes général	30
III.5	Fonctionnalités Techniques — les trois flux	30
III.5.1	Premier Flux — Webhook 1 : Analyse et Réponse	30
III.5.1.1	Principe général et découpage en six parties	30
III.5.1.2	Diagramme de séquence du Webhook 1	31
III.5.1.3	Format de la Requête Entrante	31
III.5.1.4	Les six parties du Webhook 1	32

III.5.1.4.1	Entrée fonctionnelle — analyse du message et classification d'intention	32
III.5.1.4.1.1	Branche musique — SerpAPI comme outil de recherche Google.	34
III.5.1.4.2	Confrontation à l'historique — vérification des cinq derniers messages	35
III.5.1.4.3	Classification sémantique — analyse de dépendance mémoire	36
III.5.1.4.3.1	Basic LLM Chain en lieu et place de l'AI Agent	38
III.5.1.4.3.2	Configuration OpenRouter (modèle Gemini) . .	38
III.5.1.4.3.3	OpenRouter — agrégation et suivi d'usage . . .	38
III.5.1.4.3.4	Prompt Engineering — Analyseur de Dépendance Mémoire	39
III.5.1.4.3.5	Détail des Types de Questions Classifiés	41
III.5.1.4.4	Gestion utilisateur (unkonu) : Reconnaissance et enregistrement de l'utilisateur	42
III.5.1.4.4.1	Routage par <i>Switch1</i> (résultat du la classification sémantique).	43
III.5.1.4.4.2	Diagramme de séquence — gestion utilisateur (unkonu)	44
III.5.1.4.5	Réponse contextualisée : Récupération Contextuelle et Génération de la Réponse	46
III.5.1.4.5.1	Branche Mémoirelle (<code>use_memory = true</code>) . .	46
III.5.1.4.5.2	Branche Générale (<code>use_memory = false</code>) . .	48
III.5.1.5	Vue Complète du Réponse contextualisée — Les Deux Branches	49
III.5.1.5.1	Notes et mémoire persistante : Notes, structuration et mise à jour de la mémoire	50
III.5.1.5.1.1	Partie 1 — Extraction structurée des <i>notes</i> (conditionnel).	50
III.5.1.5.1.2	Détection (<i>If</i>) et <i>Basic LLM Chain 2</i>	51
III.5.1.5.1.3	Partie 2 — Mise à jour de la mémoire et clôture du webhook.	53
III.5.1.6	Conclusion du Webhook 1	54
III.5.2	Deuxième Flux — Webhook 2 : Filtre et Synthèse Journalière	55

III.5.2.1	Principe et Inspiration	55
III.5.2.2	Diagrammes du Webhook 2	55
III.5.2.3	Fonctionnement du Webhook 2	56
III.5.2.4	Structure des Fiches de Synthèse Générées	57
III.5.2.5	Persistance : relation utilisateur / accompagnement	58
III.5.2.6	Impact sur le Système Global	59
III.5.2.7	Conclusion du Webhook 2	59
III.5.3	Troisième Flux — Webhook 3 : Spontanéité et Interaction Proactive	60
III.5.3.1	Principe : la spontanéité comme dimension humaine	60
III.5.3.2	Diagrammes du Webhook 3	60
III.5.3.3	Déclenchement et entrées	61
III.5.3.4	Préparation des données (nœud Code11)	62
III.5.3.5	Génération de l'introduction et sortie JSON	62
III.5.3.6	Conclusion du Webhook 3	63
III.6	Synthèse cognitive du Cycle 1	63
III.7	Conclusion	63
IV	Cycle 2 : Distributeur de Services	65
IV.1	Introduction	66
IV.2	Architecture Utilisée	66
IV.2.1	Choix du langage : Python	66
IV.2.2	Clean Architecture : principes et application	67
IV.2.3	Structure des répertoires du projet	68
IV.3	Fonctionnalités Techniques	69
IV.3.1	Communication avec la base de données (Supabase / PostgreSQL)	69
IV.3.1.1	Modèle relationnel et rôle des tables	70
IV.3.2	Services Azure : Speech-to-Text et Text-to-Speech	71
IV.3.3	Service de reconnaissance des personnes	73
IV.3.4	Interface avec le workflow n8n	75
IV.3.4.0.1	Images recommandées pour cette section	76
IV.3.5	Services pour l'application mobile multiplateforme	76
IV.3.6	Communication avec le système embarqué (robot réel)	78
IV.4	Problèmes Rencontrés et Solutions Apportées	78
IV.5	Conclusion	79

V	Cycle 3 : Système Embarqué — Partie Matérielle	81
V.1	Introduction	82
V.2	Architecture Matérielle Globale	82
V.3	Conception mécanique et châssis 3D (Blender)	83
V.4	Description Détaillée des Composants	84
V.4.1	Unité Centrale : Raspberry Pi 4 Model B	84
V.4.2	Unité de Commande Moteur : Arduino Uno + Shield L293D	84
V.4.3	Système d’Actionneurs	86
V.4.3.1	Moteurs DC — Mobilité	86
V.4.3.2	Servomoteurs — Articulations	86
V.4.4	Système Audio	87
V.4.4.1	Entrée Audio : ReSpeaker 4-Mic Array USB	87
V.4.4.2	Sortie Audio : double chaîne (jack filaire et Bluetooth)	87
V.4.5	Système de Vision : Caméra Raspberry Pi	88
V.4.6	Interface d’Expression Faciale : Nextion NX4832T035_011	88
V.4.7	Système d’Alimentation	89
V.5	Schéma de Câblage Global	89
V.6	Assemblage et points d’attention	90
V.7	Validation matérielle — tests par composant	90
V.7.1	Test d’intégration matérielle	91
V.8	Conclusion	91

LISTE DES FIGURES

I.1	Modèle en spirale — enchaînement des six cycles de développement KODA	9
II.1	Synthèse visuelle des besoins fonctionnels KODA (chapitre II)	13
II.2	Architecture multicouche du système KODA (vue chapitre II)	14
II.3	Acteurs principaux et contexte d'intégration du système KODA	16
II.4	Modèle en spirale et enchaînement des six cycles de développement KODA	18
II.5	Planification des cycles : jalons, chevauchements et dépendances	19
II.6	Environnement logiciel : outils de développement et chaîne technique (chapitre II) .	21
III.1	De la question à la réponse : réflexion rapide (mémoire déjà présente) ou réflexion lente (analyse puis construction)	26
III.2	Architecture cognitive de KODA inspirée de la théorie du double traitement	27
III.3	Cycle 1 — vue d'ensemble des trois workflows n8n	28
III.4	Cycle 1 — diagramme de cas d'utilisation général	29
III.5	Cycle 1 — schéma de classes général (persistance)	30
III.6	Webhook 1 — diagramme de séquence (six parties du pipeline)	31
III.7	Webhook 1 — entrée fonctionnelle (nœud <i>Test</i> , <i>Switch</i>)	32
III.8	Webhook 1 — séquence de l'entrée fonctionnelle	33
III.9	Webhook 1 — cas d'utilisation de l'entrée fonctionnelle	33
III.10	Entrée fonctionnelle — intégration SerpAPI dans le workflow n8n (branche musique du <i>Switch</i>)	35
III.11	Entrée fonctionnelle — nœud <i>Search Music</i> (SerpAPI, moteur YouTube) et exemple de sortie (<i>search_query</i> , <i>youtube_url</i>)	35
III.12	Confrontation à l'historique — workflow n8n	35
III.13	Confrontation à l'historique — diagramme de séquence	36
III.14	Classification sémantique — chaîne n8n (Code5, Identité1, Basic LLM Chain, Code2)	36
III.15	Classification sémantique — diagramme de séquence	37
III.16	Classification sémantique — cas d'utilisation	37
III.17	Classification sémantique — Paramètres du nœud OpenRouter Chat Model (creden- tial, modèle Gemini via OpenRouter)	38

III.18	Classification sémantique — tableau de bord OpenRouter (clé API workflow n8n, suivi des dépenses par modèle)	39
III.19	Gestion utilisateur (unkonu) — <i>Switch1</i> , branche enregistrement (presentation), branche LLM (unkonu) et poursuite vers la réponse contextualisée	42
III.20	Gestion utilisateur (unkonu) — Entrée JSON du <i>Switch1</i> (personne = unknow, sortie classification sémantique)	42
III.21	Gestion utilisateur (unkonu) — Sortie texte : invitation à la première rencontre et demande du prénom	43
III.22	Gestion utilisateur (unkonu) — diagramme de séquence	45
III.23	Réponse contextualisée.1 — Branche mémorielle : récupération et génération contextuelle	47
III.24	Réponse contextualisée.2 — Branche générale : contexte conversationnel et génération de réponse	49
III.25	Réponse contextualisée — Vue complète des deux branches de traitement contextuel	50
III.26	Réponse contextualisée — Diagramme de séquence du cinquième bloc	50
III.27	Notes et mémoire persistante (partie 1) — Sous-workflow n8n : test questiontype = note, <i>Basic LLM Chain 2</i> et structuration	51
III.28	Notes et mémoire persistante — Entrée JSON : question, output, personne et questiontype = note	52
III.29	Notes et mémoire persistante — Sortie JSON : date_evenement et evenement extraits du message naturel	52
III.30	Notes et mémoire persistante (partie 2) — Diagramme de classes (persistance mémoire)	54
III.31	Webhook 2 — workflow n8n	55
III.32	Webhook 2 — diagramme de séquence	56
III.33	Webhook 2 — exemple de sortie structurée (quatre dimensions de la fiche journalière)	58
III.34	Webhook 2 — schéma de persistance (utilisateur → accompagnement : interets, synthese, point_cles, conseils)	59
III.35	Webhook 3 — workflow n8n	60
III.36	Webhook 3 — diagramme de séquence	61
III.37	Webhook 3 — entrée du nœud <i>Code11</i>	62
III.38	Webhook 3 — sortie JSON (parole_du_robot, emotion_visuelle)	62
IV.1	Interface Supabase utilisée pour l'administration de la base PostgreSQL	70

IV.2	Logo SupaBase	70
IV.3	Koda Schema Base De Donnéé	71
IV.4	Capture Azur Configuration	73
IV.5	Capture Test Text To Speeach	73
IV.6	Capture Test Speeach To Text	73
IV.7	Exemple de image dans la memoire	74
IV.8	Capture Input WorkFlow (N8N)	76
V.1	Conception 3D du châssis KODA sous Blender (vue éclatée des pièces)	84
V.2	Prototype physique KODA après impression 3D et montage	85
V.3	Principe de traction différentielle — moteurs M1 et M3	87
V.4	Enchaînement conceptuel : DOA (micro) → rotation du robot (M1, M3) → caméra (torse)	88
V.5	Schéma de montage matériel de KODA — style Fritzing (Cycle 3)	89

LISTE DES TABLEAUX

II.1	Vue synthétique des cycles et livrables attendus	18
III.1	Correspondance entre mécanismes cognitifs humains et implémentations de KODA	63
IV.1	Comparaison des technologies backend envisagées	67
IV.2	Endpoints exposés à l'application mobile	77
IV.3	Problèmes techniques rencontrés et solutions apportées	79
V.1	Inventaire des composants matériels de KODA	83
V.2	Spécifications techniques du Raspberry Pi 4 Model B	86
V.3	Architecture d'alimentation de KODA	89
V.4	Récapitulatif des connexions entre composants	90
V.5	Tests unitaires par composant (Cycle 3)	91

INTRODUCTION GÉNÉRALE

Dans un monde en constante évolution technologique, la demande en solutions intelligentes capables d'améliorer la qualité de vie des individus n'a jamais été aussi forte. Les assistants virtuels et les systèmes embarqués intelligents représentent aujourd'hui une réponse concrète à ce besoin, en combinant les avancées de l'intelligence artificielle, des systèmes embarqués et du développement logiciel moderne.

Ce projet de fin d'études, réalisé dans le cadre de la formation en Développement des Systèmes Informatiques (DSI3.2) à l'ISET Mahdia, porte sur la conception et le développement de **KODA** : un assistant de vie et ami virtuel embarqué. KODA est un système robotique doté de sa propre personnalité et nature, capable de répondre intelligemment à toute personne, de raisonner à la manière d'un être humain, de reconnaître les individus à travers ses modes de sécurité, et d'être configuré et suivi via une application mobile cross-plateforme dédiée.

La problématique centrale de ce projet est : **Comment concevoir un système embarqué intelligent capable d'assurer un rôle d'assistant de vie personnalisé, intégrant reconnaissance des personnes, réflexion autonome et pilotage à distance via une application mobile ?**

Ce rapport est organisé comme suit :

- **Chapitre I** présente le cadre général du projet, l'organisme d'accueil, la problématique, l'analyse de l'existant et la solution proposée.
- **Chapitre II** expose la préparation du projet : spécification des besoins, identification des acteurs, méthodologie de pilotage *en spirale* par cycles, planification, architecture cible et environnements de travail.
- **Chapitre III** correspond au **Cycle 1 — Analyseur et réflexion** : workflows n8n (webhooks, six blocs de traitement, intégration LLM et persistance).
- **Chapitre IV** correspond au **Cycle 2** — backend *Distributeur de Services* (FastAPI, persistance, services cloud).
- **Chapitre V — Cycle 3** : système embarqué, partie matérielle (plateforme robot, câblage, validation).
- Les **cycles 4 à 6** (logiciel Raspberry Pi, application cross-plateforme, tests finaux) sont présentés dans la suite du document.

———— CHAPITRE I ————

CADRE GÉNÉRAL DU PROJET ET PRÉSENTATION DE L'ORGANISME

I.1 Introduction du chapitre

Ce chapitre esquisse le cadre fondamental de notre étude en définissant l’environnement contextuel et organisationnel du projet. Nous commençons par introduire l’organisme d’accueil, en mettant en évidence son expertise technologique et sa structure interne dédiée à l’innovation.

Ensuite, nous exposons la problématique centrale, justifiant le besoin critique d’un système intelligent. Une analyse rigoureuse des solutions existantes nous permet d’identifier les limites actuelles et de mieux positionner notre système proposé. Enfin, nous détaillons la méthodologie de projet adoptée, assurant une approche structurée et efficace tout au long du cycle de développement.

I.2 Contexte Général du Projet

L’évolution technologique actuelle transforme notre interaction avec l’environnement. La robotique sociale et les assistants personnels virtuels s’imposent comme des éléments clés pour améliorer la qualité de vie, offrant des solutions innovantes pour l’assistance quotidienne.

Le projet KODA s’inscrit dans cette dynamique en proposant un assistant de vie virtuel, conçu sous la forme d’un système embarqué intelligent. Contrairement aux solutions traditionnelles qui se limitent à l’exécution de commandes, KODA vise à offrir une véritable présence interactive, dotée d’une personnalité propre et d’une capacité de raisonnement.

La complexité de ce système réside dans l’intégration harmonieuse de multiples composants hétérogènes. Il nécessite la combinaison d’un environnement matériel embarqué (Raspberry Pi), d’un moteur de workflow intelligent (n8n) agissant comme cerveau, d’une couche logicielle orchestrant les communications (Python), et d’interfaces de contrôle intuitives (application mobile cross-plateforme). L’objectif est de créer un écosystème cohérent capable de reconnaître les utilisateurs, de traiter les requêtes de manière naturelle, et de fournir un accompagnement personnalisé.

I.3 Présentation de l’Organisme d’Accueil (MicroEdition)

I.3.1 Profil de l’Entreprise

MicroEdition est une entreprise pionnière spécialisée dans les Technologies de l’Information et de la Communication (TIC). Fondée en 2025, la société est stratégiquement implantée au sein de la Pépinière d’Entreprises de Mahdia. Cet environnement offre un écosystème robuste dédié à l’innovation, fournissant l’infrastructure nécessaire pour accompagner les startups technologiques à fort potentiel. MicroEdition se consacre à la conception et au déploiement de solutions numériques intelligentes, évolutives et sécurisées, visant à combler le fossé entre la recherche académique et

l'application industrielle.

I.3.2 Services

Le portefeuille de l'entreprise repose sur trois piliers technologiques fondamentaux :

- **Développement logiciel** : Conception d'applications web et mobiles haute performance, adaptées à des logiques métier spécifiques.
- **Internet des Objets (IoT)** : Conception d'écosystèmes connectés de bout en bout pour l'automatisation industrielle et agricole.
- **Cybersécurité** : Mise en œuvre de protocoles de sécurité rigoureux pour protéger les actifs numériques et garantir l'intégrité des données dans les secteurs public et privé.

I.3.3 Recherche & Développement (R&D)

Un trait distinctif de MicroEdition est sa division spécialisée en Recherche et Développement. Ce département se concentre fortement sur l'IA embarquée (Edge AI) et l'intelligence embarquée. En explorant des méthodologies d'exécution de réseaux de neurones complexes directement sur des microcontrôleurs, l'équipe R&D cherche à éliminer la dépendance à une connectivité cloud permanente. Cet axe stratégique est central pour le projet KODA, car il permet la création de systèmes autonomes et résilients capables de fonctionner dans des environnements où l'accès à Internet peut être intermittent.

I.3.4 Structure Organisationnelle

MicroEdition fonctionne selon un cadre Agile qui met l'accent sur l'itération rapide et la collaboration interdisciplinaire. La structure interne de l'entreprise est composée d'unités spécialisées, notamment :

- **Architectes logiciels** : Conception de backends systèmes évolutifs.
- **Ingénieurs en systèmes embarqués** : Pont entre le matériel et le logiciel.
- **Spécialistes en IA et Data Scientists** : Développement et optimisation de modèles d'apprentissage automatique pour le déploiement embarqué.

Cette synergie permet à MicroEdition de maintenir un cycle d'innovation soutenu, garantissant que chaque projet — tel que KODA — repose sur des fondations d'excellence technique et de standards architecturaux modernes.

I.4 Problématique

L'évolution constante de notre société moderne, marquée par un rythme de vie accéléré et une digitalisation croissante, a paradoxalement accentué certains besoins fondamentaux de l'être humain, notamment celui de l'accompagnement et de l'interaction sociale.

Le problème central auquel nous tentons de répondre s'articule autour de trois axes principaux :

A. Le besoin de présence et d'interaction naturelle

Malgré la prolifération des appareils connectés, la plupart des outils actuels (smartphones, enceintes connectées classiques) restent des outils purement fonctionnels. Ils exécutent des ordres mais n'offrent pas de réelle interaction "humaine". Il existe un manque flagrant de systèmes capables d'afficher une personnalité propre et de simuler une forme de réflexion empathique capable de briser la solitude ou d'assister l'utilisateur au quotidien.

B. La complexité de la gestion de vie autonome

Dans un environnement domestique, la gestion des tâches, de la sécurité et du suivi technique des objets connectés devient de plus en plus complexe pour l'utilisateur moyen. Il n'existe pas de solution centralisée qui combine à la fois un assistant de vie intelligent (capable de raisonner) et un système de sécurité actif (capable de reconnaître les personnes et de protéger l'habitat).

C. Les limites de l'intelligence statique

La majorité des assistants actuels dépendent de réponses préprogrammées et rigides. Le défi est de passer d'une machine qui "répond" à une machine qui "réfléchit" et "apprend". Le problème est donc de concevoir une architecture capable de :

- Identifier l'interlocuteur de manière sécurisée.
- Traiter des demandes complexes de manière fluide et humaine.
- Offrir une interface de contrôle simple (application mobile) pour superviser cette "vie artificielle".

En résumé, la question fondamentale de notre projet est la suivante : **Comment concevoir un compagnon robotique intelligent, doté d'une mémoire et d'une personnalité, capable d'offrir un accompagnement humain authentique tout en assurant une gestion technique et sécurisée de l'environnement de l'utilisateur ?**

I.5 Analyse des Solutions Existantes

I.5.1 Étude de l'existant

Dans cette section, nous examinons les assistants domestiques et les robots compagnons les plus populaires sur le marché afin d'identifier leurs forces et leurs lacunes.

- **A. Les Assistants Vocaux Statiques (Amazon Alexa, Google Home)**

Ces dispositifs sont les plus répandus. Ils excellent dans l'exécution de tâches simples (domotique, rappels, recherches internet).

Limites : Ils n'ont pas de présence physique mobile. Surtout, ils restent des outils purement réactifs : ils attendent un "mot déclencheur" et répondent de manière standardisée. Il n'y a aucune notion de "personnalité" évolutive ou de sentiment d'appartenance.

- **B. Les Robots Domestiques (ex : Amazon Astro, Vector/Cozmo)**

Certains robots essaient d'occuper l'espace physique. Amazon Astro, par exemple, surveille la maison et suit l'utilisateur.

Limites : Bien que mobiles, ces produits restent perçus comme des gadgets technologiques. Leur interaction est limitée par des scripts pré-enregistrés. Ils ne "réfléchissent" pas de manière humaine et leur capacité à reconnaître et s'adapter à l'humeur ou à l'identité spécifique de chaque membre de la famille de façon approfondie reste superficielle.

- **C. Les Pepper & Nao (Robotique de service)**

Ce sont des robots haut de gamme capables de simuler des émotions et de reconnaître des visages.

Limites : Ces solutions sont extrêmement coûteuses (plusieurs milliers d'euros) et sont destinées aux entreprises plutôt qu'au grand public. Leur configuration est complexe et ils ne sont pas conçus comme des "amis" personnels intégrés à un écosystème mobile fluide pour l'utilisateur lambda.

I.5.2 Synthèse et Critique : Le "Manque d'Humanité"

Le point commun de tous ces concurrents est leur nature générique. Ce sont des machines produites en série qui traitent chaque utilisateur de la même manière.

- **Absence de personnalité** : La réponse d'une Alexa est la même pour tout le monde. Elle n'a pas de "caractère" propre qui pourrait la faire passer pour un compagnon de vie.
- **Froideur algorithmique** : Les interactions sont basées sur des arbres de décision rigides. L'utilisateur sent qu'il parle à une base de données, pas à une entité qui "réfléchit".

- **Dépendance au Cloud propriétaire** : L'utilisateur a peu de contrôle sur la "mémoire" ou la logique interne de l'assistant.

I.5.3 La Différenciation de Koda

C'est ici que notre projet se distingue. Contrairement aux machines industrielles, Koda est conçu pour être :

- **Unique** : Grâce à l'intégration de n8n (le cœur de réflexion), Koda peut avoir une logique de réponse personnalisée et évolutive.
- **Multimodal** : Il combine la vision (Raspberry Pi), la réflexion (IA via n8n) et la mobilité.
- **Accessible** : Une application mobile dédiée permet de configurer sa "personnalité", rendant l'utilisateur maître de son compagnon.

I.6 Solution Proposée

Pour surmonter ces limitations, nous proposons KODA, une architecture résiliente et multi-couche conçue pour l'autonomie et l'intelligence. La solution comprend :

- **Contrôleur Embarqué (Raspberry Pi)** : Le cœur physique du système, gérant les composants matériels et assurant le fonctionnement du robot.
- **Moteur de Réflexion (n8n)** : Le cerveau de KODA, responsable de la préparation des réponses et du traitement intelligent des requêtes complexes.
- **Couche de Distribution (Python)** : Le système nerveux responsable de la communication entre n8n, la base de données, l'application mobile et le Raspberry Pi, offrant les points d'accès (endpoints) de tout l'écosystème.
- **Expérience Utilisateur Mobile** : Une application cross-plateforme permettant à l'utilisateur de configurer, contrôler et suivre la vie de son compagnon robotique en temps réel.
- **Mémoire Persistante (Base de données)** : Un système de stockage permettant à KODA d'enregistrer des informations contextuelles et d'apprendre de ses interactions.

En intégrant ces composants, la solution proposée garantit une résilience opérationnelle, des interactions humaines authentiques et une expérience de gestion unifiée.

I.7 Méthodologie du Projet

Pour garantir un haut degré de fiabilité et une intégration harmonieuse des différentes couches logicielles et matérielles, ce projet suit un cadre d'ingénierie rigoureux.

I.7.1 Modèle en spirale

Le pilotage du projet KODA repose sur le **modèle en spirale**, et non sur un cycle en V séquentiel ni sur une succession de sprints Scrum. À chaque tour de spirale, une partie du système est **précisée, construite, testée** et **raccordée** au reste ; avant d'engager le tour suivant, l'équipe **réévalue les risques** (techniques, d'intégration, de délai) et ajuste les priorités. Cette démarche convient à un compagnon robotique multicouche : on ne livre pas tout d'un coup, on fait monter en puissance le moteur de réflexion, le lien avec le robot, l'application mobile, puis la validation d'ensemble.

Le périmètre est découpé en **six cycles thématiques**, ordonnés de façon logique :

1. analyse et réflexion (moteur conversationnel) ;
2. couche de distribution et persistance des données ;
3. partie matérielle embarquée ;
4. partie logicielle sur le robot ;
5. application mobile de pilotage ;
6. tests et validation globale.

Chaque cycle se clôt par un **incrément démontrable** (fonctionnalité branchée, scénario utilisateur, critères d'acceptation) et par un point de synchronisation avec l'encadrement. La planification détaillée, les rôles et le calendrier des jalons sont formalisés au chapitre II ; la figure ci-dessous en résume le principe.

Artefacts et traçabilité

À chaque tour, des livrables assurent la continuité entre les cycles :

- **Besoins et périmètre** mis à jour (utilisateur, sécurité, mémoire).
- **Architecture et intégration** (schémas, interfaces entre robot, logiciel de réflexion, application).
- **Réalisation et recette** du cycle en cours (tests, démonstration, correctifs avant le tour suivant).

I.8 Conclusion

Ce chapitre a établi le contexte du projet KODA. En identifiant les lacunes critiques des assistants virtuels actuels — notamment le manque de personnalité, de réflexion autonome et d'intégration




FIGURE I.1 – Modèle en spirale — enchaînement des six cycles de développement KODA

embarquée — nous avons défini notre solution innovante. Le **modèle en spirale** et les six cycles de développement posent une feuille de route incrémentale, adaptée à la complexité d'un système distribué entre compagnon physique, réflexion et pilotage mobile.

Le chapitre suivant, «**Préparation du Projet**», formalise les besoins, la méthodologie de développement **en spirale** par cycles successifs et les environnements techniques retenus pour mener à bien la réalisation de KODA.

_____ CHAPITRE II _____

PRÉPARATION DU PROJET

II.1 Introduction du chapitre

Ce chapitre pose les fondations ingénierie du projet **KODA** avant d’entrer dans le détail technique des cycles de réalisation. Nous y traduisons l’intention du chapitre I en **exigences traçables** (fonctionnelles et non fonctionnelles), en **vision architecturale** et en **périmètre d’acteurs**. Nous y présentons également la **méthodologie de pilotage** retenue : le **modèle en spirale**, fondé sur des **cycles de développement successifs** — et non sur une succession de sprints Scrum — où chaque tour de spirale livre un incrément (couche ou sous-système) intégrable et réévalue les risques avant le tour suivant. Enfin, nous documentons les environnements matériel et logiciel qui ont encadré la production du prototype.

II.2 Spécification des besoins

II.2.1 Spécifications des besoins fonctionnels

Les besoins fonctionnels précisent *ce que* KODA doit offrir à l’utilisateur, sans décrire encore les choix d’implémentation. Ils reprennent la problématique du chapitre I : un **compagnon de vie** capable de présence, de réflexion et d’accompagnement personnalisé, et non un simple exécuteur de commandes.

- **Dialoguer naturellement** : l’utilisateur s’adresse à KODA à l’oral ou par message ; le compagnon comprend la demande, y répond de façon claire et pertinente, et adapte son ton à la situation (explication, conseil, réconfort). Lorsque la question appelle une réponse immédiate (arrêt, mot de passe, musique, déplacement), KODA réagit sans détour ; sinon, il prend le temps d’analyser avant de répondre.
- **Se souvenir et personnaliser** : KODA reconnaît les personnes avec lesquelles il interagit, retient leurs présentations, leurs préférences et les éléments importants de leurs échanges (notes, informations personnelles). Il peut répondre en s’appuyant sur ce qu’il sait déjà de l’utilisateur, ou traiter une question générale sans tout reconsulter ; la mémoire est consolidée au fil du temps pour garder une continuité dans la relation.
- **Reconnaître et accueillir** : le compagnon identifie l’interlocuteur (visage, contexte) et adapte son comportement : accueil personnalisé pour une personne connue, invitation à se présenter pour un visiteur inconnu, conformément à l’objectif de présence humaine évoqué au chapitre I.
- **Être présent physiquement** : le robot matérialise l’interaction (captures, parole, déplacements ou signaux prévus par le prototype) et reste relié au reste du système pour que l’expérience ne se limite pas à un écran ou à une enceinte déconnectée du corps du compagnon.

- **Permettre le pilotage à distance** : via l'application mobile, l'utilisateur configure la personnalité de KODA (nom, caractère, langue, etc.), suit son activité et supervise son compagnon au quotidien, comme annoncé dans la solution proposée au chapitre I.
- **Protéger l'usage et l'environnement** : KODA fonctionne selon des modes ouvert ou protégé (mot de passe), afin de limiter l'accès aux fonctions sensibles lorsque le compagnon est en mode sécurisé; cette exigence répond au besoin, formulé au chapitre I, d'allier accompagnement humain et gestion responsable de l'environnement domestique.




FIGURE II.1 – Synthèse visuelle des besoins fonctionnels KODA (chapitre II)

II.2.2 Spécification des besoins non fonctionnels

Les besoins non fonctionnels décrivent *comment* le système doit se comporter pour être acceptable au quotidien : fiabilité, confiance, simplicité d'évolution. Ils complètent les besoins fonctionnels sans entrer dans le détail des outils retenus aux chapitres techniques suivants.

- **Réactivité perçue** : les réponses du compagnon doivent paraître fluides à l'utilisateur, y compris lorsque le traitement s'appuie sur des services en ligne (recherche, synthèse vocale, etc.); les échanges déjà connus ne doivent pas systématiquement être retraités comme s'il n'y avait aucune mémoire.
- **Continuité de service** : une coupure partielle d'un service distant ne doit pas faire perdre l'essentiel des données ni bloquer durablement l'interaction; les informations importantes (profils, historiques, paramètres) restent conservées de façon durable.
- **Confiance et respect de la vie privée** : seules les personnes autorisées accèdent aux fonctions sensibles; les identifiants et données personnelles sont protégés, et le compagnon n'expose pas inutilement ce qu'il sait de l'utilisateur.

- **Clarté pour l'équipe projet** : la logique est organisée par blocs (dialogue, mémoire, robot, application) afin de pouvoir corriger ou enrichir une partie sans remettre en cause tout le système ; les scénarios principaux restent documentés pour la validation en fin de cycle.
- **Ouverture aux évolutions** : il doit être possible d'ajouter une nouvelle capacité (type de question, écran mobile, capteur) en s'appuyant sur l'architecture globale du chapitre I, sans repartir d'une conception entièrement nouvelle.
- **Accessibilité d'usage** : l'application de pilotage et les modes du compagnon restent compréhensibles pour un utilisateur non spécialiste, en ligne avec l'objectif d'un compagnon « accessible » par rapport aux robots professionnels coûteux évoqués dans l'analyse de l'existant.

II.2.3 Architecture du système

L'architecture cible est **multicouche** et **distribuée** : un moteur d'automatisation (**n8n**) concentre la logique métier conversationnelle ; un **backend Python (FastAPI)** centralise les accès données et les intégrations cloud ; un **noyau embarqué (Raspberry Pi)** assure le lien avec le monde physique ; une **application mobile** prolonge l'expérience utilisateur ; une **base PostgreSQL** matérialise la mémoire long terme. La figure II.2 (chapitre I et II) illustre cette décomposition ; les cycles de développement du présent rapport s'alignent sur ces blocs pour réduire le rayon d'intégration à chaque itération.




FIGURE II.2 – Architecture multicouche du système KODA (vue chapitre II)

II.2.4 Identification des acteurs

On distingue notamment :

- l'**Utilisateur final** (personne qui dialogue avec KODA et configure l'application) ;
- le **système KODA** (ensemble logiciel/matériel) ;
- le **Distributeur de services** (backend) en tant qu'intermédiaire technique ;
- les **services externes** (Supabase, OpenRouter pour les LLM, SerpAPI pour la recherche musique au Block 1, Azure pour la voix et la vision) ;
- l'**organisme d'accueil** et l'**équipe projet** (rôles de pilotage et de validation).




FIGURE II.3 – Acteurs principaux et contexte d'intégration du système KODA

II.3 Pilotage du projet — Modèle en spirale et cycles de développement

Contrairement à une approche **Agile Scrum** fondée sur des *sprints* de durée fixe avec cérémonies prescrites (daily, review, rétrospective), nous avons retenu le **modèle en spirale** : à chaque itération, une portion du produit (cycle thématique : workflows n8n, backend, matériel, logiciel embarqué, mobile, validation) est **spécifiée, réalisée** puis **intégrée** au système global, avec une **réévaluation des risques** et des priorités avant le tour suivant. Chaque cycle produit un incrément **testable** et raccordé aux livrables des tours précédents, jusqu'à stabiliser l'écosystème KODA complet.

II.3.1 Équipe et rôles

Le projet est conduit par une **équipe de projet de fin d'études** (DSI3.2, ISET Mahdia), en binôme, sous la responsabilité d'un **encadrant académique** et en lien avec l'**organisme d'accueil** MicroEdition (cf. chapitre I). Les rôles se répartissent entre conception des workflows n8n, développement backend, intégration embarquée, développement mobile et campagne de tests, avec des points de synchronisation à la fin de chaque cycle pour valider l'intégration incrémentale.

II.3.2 Découpage du travail : six cycles

Le périmètre fonctionnel est découpé en six cycles **ordonnés logiquement** — sans équivalence directe avec des sprints Scrum — comme suit :

1. **Cycle 1 — Workflow et n8n** : conception des webhooks, blocs de traitement (classification d'intention, analyseur de dépendance mémoire, consolidation, proactivité), intégration des API LLM et recherche.
2. **Cycle 2 — Backend** : Distributeur de services (FastAPI), accès PostgreSQL / Supabase, Clean Architecture, endpoints pour le robot et le mobile.
3. **Cycle 3 — Système embarqué, partie matérielle** : choix et câblage des capteurs, actionneurs, alimentation, mécanique ou support physique associé au Raspberry Pi selon le prototype.
4. **Cycle 4 — Système embarqué, partie logicielle (Raspberry Pi)** : logiciel embarqué, communication avec le backend, gestion des flux audio/vidéo locaux, robustesse sur carte ARM.
5. **Cycle 5 — Cross-plateforme** : application mobile (configuration, suivi, notifications), parcours utilisateur unifiés Android/iOS.
6. **Cycle 6 — Tests et validation** : tests unitaires et d'intégration, scénarios bout-en-bout, validation des besoins non fonctionnels (sécurité, performance).

TABLE II.1 – Vue synthétique des cycles et livrables attendus

Cycle	Thème	Livrable principal
1	Workflow n8n	Webhooks opérationnels, prompts et routages stabilisés
2	Backend	API documentée, persistance, intégrations cloud
3	Embarqué HW	Plateforme physique prête à accueillir le logiciel
4	Embarqué SW (Pi)	Services locaux et dialogue avec le Distributeur
5	Cross-plateforme	Application mobile utilisable sur les cibles
6	Tests & validation	Rapport de recette, correctifs de fin de projet




FIGURE II.4 – Modèle en spirale et enchaînement des six cycles de développement KODA

II.4 Planification des cycles

La planification ne s'exprime pas en **sprints** de deux semaines mais en **jalons de cycles** : chaque cycle se termine par une **démonstration intégrée** (workflow branché sur le backend, backend branché sur la base, puis ajout du Raspberry Pi, etc.). Les dépendances imposent un ordre raisonnable : le moteur n8n (cycle 1) et le backend (cycle 2) peuvent avancer en parallèle partiel, mais la validation bout-en-bout (cycle 6) recouvre l'ensemble. Le calendrier académique du PFE (nombre de semaines, séances de suivi, livrables intermédiaires) structure la cadence réelle ; le **modèle en spirale** en garantit la **cohérence** : aucun cycle ne clôt sans critères d'acceptation liés aux chapitres techniques correspondants du rapport.




FIGURE II.5 – Planification des cycles : jalons, chevauchements et dépendances

II.5 Architecture

II.5.1 Architecture de l'application

Au-delà du schéma global (chapitre I), l'architecture applicative distingue : **(a)** la couche *présentation* (mobile) ; **(b)** la couche *orchestration intelligente* (n8n) ; **(c)** la couche *services* (FastAPI) ; **(d)** la couche *données* (PostgreSQL) ; **(e)** la couche *embarquée* (Raspberry Pi). Les communications principales suivent le modèle requête-réponse REST et événements asynchrones selon les besoins (temps réel, webhooks). Cette structuration facilite le parallélisme des cycles tout en conservant des interfaces stables entre équipes.

II.5.1.1 Architecture en oignon (Onion Architecture) du backend

Le **Distributeur de services** (backend Python, cycle 2) adopte une **architecture en oignon** : les couches sont organisées en **anneaux concentriques**, du plus stable au plus volatile. Au **cœur** se trouvent le **domaine métier** (entités, règles) ; autour, les **cas d'usage** orchestrent les scénarios

sans dépendre des frameworks ; puis viennent les **adaptateurs** (API REST, sérialisation, accès données) ; en périphérie, la **infrastructure** (FastAPI, Supabase, SDK Azure, clients HTTP vers n8n ou le robot). Les dépendances pointent **toujours vers l'intérieur**, ce qui isole la logique métier des technologies et facilite les tests unitaires sur le domaine.

Ce modèle — popularisé notamment par Jeffrey Palermo sous le nom d'*Onion Architecture* — recoupe les principes de la **Clean Architecture** détaillés au chapitre du cycle 2 : les deux visions décrivent des couches concentriques et la règle d'inversion des dépendances ; l'« oignon » met l'accent sur la **testabilité** du noyau et sur le fait que l'infrastructure soit interchangeable sans toucher au cœur du système. Ainsi, le backend KODA reste cohérent avec la vision multicouche de la figure II.2 tout en précisant sa structure interne.

II.6 Environnement de Developement

II.6.1 Environnement matériel

Le développement s'appuie sur des postes de travail type PC (processeur multi-cœurs, au moins 8 Go de RAM recommandés pour les outils de conteneurisation et les IDE), un **Raspberry Pi** cible pour les tests embarqués, périphériques audio/vidéo selon les besoins du robot, et un smartphone ou émulateur pour la couche mobile. Un accès Internet stable est nécessaire pour Supabase, OpenRouter, SerpAPI et Azure durant l'intégration.

*Emplacement réservé — photographie à insérer sous le nom
public/ch2-environnement-materiel.png (PC, Raspberry Pi, périphériques du
robot).*

II.7 Environnement logiciel

II.7.1 Outils de développement et modélisation

- **n8n** (self-hosted ou cloud) pour l'édition des workflows ;
- **Visual Studio Code** ou équivalent pour Python, Dart et LaTeX ;
- **Git** pour le versioning ;
- **PlantUML** / captures d'écran pour les diagrammes de séquence et de cas d'utilisation ;
- **Supabase Studio** pour l'administration PostgreSQL ;

- **Docker** (le cas échéant) pour le déploiement du backend et la reproductibilité des environnements.

II.7.2 Langages et frameworks utilisés

- **JavaScript** (expressions n8n, nœuds Code);
- **Python 3** avec **FastAPI**, SQLAlchemy, asyncpg, SDK Azure et intégrations Gemini/OpenRouter côté Distributeur;
- **SQL** (PostgreSQL);
- **Dart / Flutter** pour l'application cross-plateforme;
- **Bash** et utilitaires système sur Raspberry Pi OS.




FIGURE II.6 – Environnement logiciel : outils de développement et chaîne technique (chapitre II)

II.8 Figures et diagrammes prévus pour ce chapitre

Pour illustrer le chapitre II dans le PDF final, les captures et exports suivants sont recommandés. Les noms de fichiers sont normalisés **sans espace** (dossier public/) afin d'éviter les erreurs de compilation $\text{\LaTeX}$; il suffit de créer chaque fichier sous ce nom puis d'insérer `\includegraphics` dans la section concernée.

Réutilisation possible : la figure d'architecture multicouche du chapitre I (public/ch2-architecture-systeme) peut être réutilisée ou déclinée pour d'autres sections après recadrage ou légende adaptée au § 2.2.3 / 2.5. Le **modèle en spirale** introduit au chapitre I est détaillé ici (cycles, planification, figure II.4).

II.9 Conclusion

Ce chapitre a cadré la préparation de KODA : besoins fonctionnels et non fonctionnels, acteurs, architecture de référence, environnements, et surtout un **modèle en spirale** articulé en six cycles — en rupture avec une gestion purement Scrum/sprint, tout en conservant l'esprit d'incrémentalité et de revue de fin de cycle. Le chapitre suivant détaille le **Cycle 1 (Analyseur et réflexion)** : workflows n8n.

_____ CHAPITRE III _____

CYCLE 1 : ANALYSEUR ET RÉFLEXION

III.1 Introduction

Le **Cycle 1 — Analyseur et réflexion** constitue le **moteur cognitif** de KODA. Son rôle est double : assurer la **génération des réponses** lorsque l'utilisateur pose une question, et alimenter la **spontanéité** du robot lorsqu'il prend l'initiative de parler. L'objectif poursuivi est de développer un système capable d'**accueillir une question**, de la **comprendre dans son contexte**, d'effectuer les **recherches et consultations** nécessaires (mémoire, profil, services externes), puis de **formuler et restituer une réponse** adaptée.

La chaîne de traitement — de l'entrée utilisateur à la réponse — forme une **ligne de processus** successifs. Les **outils d'automatisation de flux** offrent une meilleure lisibilité et un débogage par étape que du code monolithique ; la **bonne pratique** retenue est la plateforme **n8n**, auto-hébergée et adaptée aux pipelines mêlant règles métier et intelligence artificielle.

Trois **webhooks** n8n structurent ce cycle. Après les fondements théoriques, la modélisation globale puis l'analyse détaillée de chaque flux, le lecteur dispose d'une vue complète du moteur d'analyse et de réflexion.

III.2 Fondements Théoriques

Cette section pose le **cadre cognitif** du Cycle 1. Elle explique, en termes généraux, comment une personne comprend une question et choisit une réponse ; elle ne décrit pas encore les outils informatiques (n8n, webhooks, base de données), traités aux sections suivantes.

III.2.1 Que signifie « théorie du double traitement » ?

L'expression **théorie du double traitement** (*dual-process theory*) désigne une idée simple : face à une question, l'esprit humain ne suit pas toujours le même chemin. Selon la situation, il peut répondre **presque tout de suite** en s'appuyant sur ce qu'il sait déjà, ou réfléchir **plus longtemps** en recomposant des éléments mémorisés. Ce modèle, largement diffusé par Daniel Kahneman (*Thinking, Fast and Slow*, 2011), aide à comprendre pourquoi certaines réponses sont instantanées et d'autres demandent un effort conscient.

En psychologie cognitive, on parle souvent de **cognition intuitive** (rapide) et de **cognition analytique** (lente), plutôt que de « système 1 » et « système 2 » : ces derniers termes sont des étiquettes de laboratoire peu parlantes pour le lecteur non spécialiste. Nous les remplaçons donc par des formulations explicites ci-dessous.

III.2.2 Réflexion rapide et réflexion lente

III.2.2.1 *Réflexion rapide : réutiliser la mémoire déjà présente*

La **réflexion rapide** correspond à une **cognition heuristique** : le cerveau repère un schéma connu et active presque aussitôt un souvenir, une habitude ou une règle déjà apprise. La réponse paraît « évidente » parce qu'elle ne reconstruit pas toute la situation depuis zéro ; elle **s'appuie sur la mémoire déjà là** : souvenirs récents de la conversation, image de l'interlocuteur, faits appris par cœur, gestes routiniers (saluer, donner son prénom, réciter une capitale connue).

Cette voie est **économique en attention** : elle convient lorsque la question ressemble à quelque chose de déjà vécu ou lorsque l'information demandée est directement stockée. Elle peut toutefois se tromper si le contexte a changé sans que l'on s'en aperçoive (réponse trop hâtive fondée sur une analogie fausse).

III.2.2.2 *Réflexion lente : analyser la mémoire pour fabriquer une réponse*

La **réflexion lente** correspond à une **cognition analytique** : le cerveau **parcourt, compare et combine** des éléments en mémoire pour **construire** une réponse nouvelle. Elle intervient lorsque la question est floue, inédite, émotionnellement chargée ou exige de croiser plusieurs souvenirs (passés lointains, préférences de l'interlocuteur, règles implicites de politesse, conséquences d'un choix).

Elle est **plus lente** précisément parce qu'elle ne se contente pas d'un rappel automatique : elle **analyse** le contenu mémorisé (épisodes, connaissances, sentiments) avant de formuler une phrase adaptée. On peut encore corriger ou affiner la réponse une fois qu'elle est énoncée (reformulation, nuance, excuse).

Les deux voies **coopèrent** : la réflexion rapide propose souvent une première piste ; la réflexion lente peut la confirmer, la nuancer ou la remplacer.

III.2.3 Comment une question est comprise avant la réponse

Qu'une question arrive à l'**oral** ou à l'**écrit**, le déroulement général est le suivant :

1. **Percevoir la question** : entendre ou lire les mots, filtrer le bruit, porter attention à l'interlocuteur.
2. **Comprendre le sens** : saisir ce qui est demandé (information, avis, souhait, plaisanterie) et le contexte immédiat (qui parle, de quoi on parlait juste avant).
3. **Mobiliser la mémoire** : faire remonter des souvenirs utiles : échanges récents, connaissances générales, image de la relation avec cette personne.
4. **Choisir la voie rapide ou lente** : si un souvenir pertinent « saute aux yeux », la réflexion rapide

suffit ; sinon, la réflexion lente assemble et vérifie les éléments avant de répondre.

5. **Formuler et, si besoin, ajuster** : prononcer ou écrire la réponse, puis la corriger si elle sonne faux ou incomplet.




FIGURE III.1 – De la question à la réponse : réflexion rapide (mémoire déjà présente) ou réflexion lente (analyse puis construction)

III.2.4 Intérêt pour un compagnon conversationnel comme KODA

Un robot compagnon doit imiter cette logique humaine : parfois répondre vite en réutilisant ce qui vient d'être dit ou mémorisé sur l'utilisateur ; parfois prendre le temps d'**interpréter** la demande et d'**élaborer** une réponse plus personnalisée. Le Cycle 1 matérialise ce principe dans l'implémentation technique, décrite à partir de la section III.4 ; la figure III.4 en donne une vue d'ensemble une fois les notions d'outillage posées.

Références : Kahneman, D. (2011). *Thinking, Fast and Slow* ; Evans, J.St.B.T. (2008). Dual-processing accou

III.3 Définitions Fondamentales

Le Cycle 1 s'appuie sur **n8n** (automatisation par workflows et nœuds, données JSON, auto-hébergement) et sur trois **webhooks** HTTP déclenchant les pipelines d'analyse, de synthèse et de spontanéité. Les appels aux modèles de langage passent par **OpenRouter**, agrégateur d'API modèles utilisé dans les nœuds n8n de type *Basic LLM Chain* ou *AI Agent*.

III.3.1 Grand modèle de langage (LLM)

Un **grand modèle de langage** — en anglais *Large Language Model*, souvent abrégé **LLM** — est un modèle de **apprentissage profond** entraîné sur d’immenses corpus textuels pour prédire la suite probable de tokens (mots ou sous-mots). Il sait produire du texte fluide, suivre des consignes (*prompts*), classer ou reformuler des entrées, et combiner plusieurs contraintes lorsque le prompt est bien structuré.

Dans n8n, un LLM est typiquement invoqué via des nœuds de type **Basic LLM Chain** ou **AI Agent** : le workflow transmet un prompt système et le message utilisateur ; le modèle renvoie une **complétion textuelle** exploitable par les nœuds aval (parsing JSON, routage, réponse au webhook). Dans la **classification sémantique** du premier flux, le LLM joue le rôle d’**Analyseur de Dépendance Mémoire** : il décide si une consultation de la base est nécessaire et assigne une catégorie, sous une forme de sortie strictement contrôlée (lignes `USE_MEMORY` / `NO_MEMORY`, etc.).

Référence : Russell & Norvig (2010), *Artificial Intelligence : A Modern Approach*.

III.4 Modélisation globale du Cycle 1

La modélisation suivante traduit, sur le plan technique, la distinction entre **réflexion rapide** (réutilisation de l’historique récent) et **réflexion lente** (analyse approfondie avant réponse), introduite au § III.2.




FIGURE III.2 – Architecture cognitive de KODA inspirée de la théorie du double traitement

III.4.1 Vue d'ensemble des trois flux n8n




FIGURE III.3 – Cycle 1 — vue d'ensemble des trois workflows n8n

III.4.2 Diagramme de cas d'utilisation général




FIGURE III.4 – Cycle 1 — diagramme de cas d'utilisation général

III.4.3 Schéma de classes général




FIGURE III.5 – Cycle 1 — schéma de classes général (persistance)

III.5 Fonctionnalités Techniques — les trois flux

III.5.1 Premier Flux — Webhook 1 : Analyse et Réponse

III.5.1.1 Principe général et découpage en six parties

Le **Webhook 1** est le pipeline principal en temps réel. Il se décompose en six parties, dans l'ordre de la figure III.5.1.2 : *entrée fonctionnelle*, *confrontation à l'historique*, *classification sémantique*, *utilisateur connu ou inconnu*, *réponse contextualisée*, *notes et mémoire persistante*.

III.5.1.2 Diagramme de séquence du Webhook 1




FIGURE III.6 – Webhook 1 — diagramme de séquence (six parties du pipeline)

III.5.1.3 Format de la Requête Entrante

Le webhook accepte les requêtes au format (`user_name` + `question`). Le champ `user_name` est un identifiant unique généré automatiquement par le backend pour chaque utilisateur en cours d'interaction. Cet identifiant est injecté avec la question dans le flux de travail, permettant d'isoler et de gérer les données de chaque utilisateur de manière indépendante dans les environnements multi-utilisateurs.

III.5.1.4 Les six parties du Webhook 1

III.5.1.4.1 Entrée fonctionnelle — analyse du message et classification d'intention




FIGURE III.7 – Webhook 1 — entrée fonctionnelle (nœud *Test*, *Switch*)




FIGURE III.8 – Webhook 1 — séquence de l’entrée fonctionnelle




FIGURE III.9 – Webhook 1 — cas d’utilisation de l’entrée fonctionnelle

Dès l’appel au webhook et la lecture du message de chat (chatInput), le flux interroge la base (nœud PostgreSQL *Identité*) pour récupérer au minimum le **mot de passe** attendu et l’**état** courant du robot (etat). Le nœud Code **Test** consolide ces données et le texte saisi par l’utilisateur afin de produire une **intention** unique consommée par le nœud *Switch* en aval. Ce *Switch* (six sorties, voir figure III.5.1.4.1) active l’une des branches métier (musique via SerpAPI, arrêt / authentification via

requêtes *Identité4–5*, direction, historique comparé, branche *Code10*, etc.) décrite par le diagramme de séquence source `plantuml/koda-block1-switch-six-branches-sequence.puml`.

Le message est d’abord normalisé en **minuscules** pour les détections par sous-chaîne. La logique applique une **priorité fixe** entre les intentions reconnues :

1. **Fermeture** (*ferme*) : une liste étendue de formulations (*ferme, off, mode off, bye, au revoir, shutdown, sleep, etc.*) est testée par `includes` sur le texte en minuscules.
2. **Mot de passe** (*motdepasse*) : comparaison **stricte** (`===`) entre le message original et la valeur `motdepasse` issue de la base ; utilisée pour valider l’ouverture lorsque le robot est en mode protégé.
3. **Musique** (*musique*) : détection des mots-clés *chante* ou *lire* ; si l’un est trouvé, le segment **après** ce mot-clé est extrait comme nom de chanson (`nomChanson`) lorsqu’il n’est pas vide.
4. **Direction** (*direction*) : recherche du premier terme parmi *avant, droite, gauche, derriere, stope, stop* présent dans le message (ordre de la liste).
5. **Inconnu** (*inconnu*) : valeur par défaut de intention si aucune des intentions précédentes n’est détectée ; en parallèle, le booléen `estInconnu` vaut `true` lorsque aucune fermeture, aucune correspondance mot de passe, aucune musique ni direction n’est reconnue **et** que `etat == 1` (permet au workflow de traiter le cas « message non classé » selon la branche prévue, par exemple arrêt ou message dédié).

Le nœud renvoie un objet JSON regroupant les indicateurs booléens (`contientFerme, motdepasseexiste, contientPlay`), les champs extraits (`nomChanson, direction`), `estInconnu`, l’intention finale, le message original, ainsi que `directionvariable` (vrai si aucune direction) et `etat` pour les nœuds suivants. Ainsi, l’entrée fonctionnelle ne se limite plus à un simple garde-fou d’état : il **centralise la sémantique opérationnelle** du message (arrêt, authentification, média, déplacement) avant le routage `n8n`.

III.5.1.4.1.1 Branche musique — SerpAPI comme outil de recherche Google.

Lorsque l’intention vaut musique, le *Switch* active une branche dédiée qui n’utilise **pas** de modèle de langage : elle s’appuie sur **SerpAPI**, service tiers exposant une API de **recherche structurée** (moteur youtube dans notre configuration). Si l’utilisateur demande de **chanter** ou de **lire** un morceau (MP3 / audio), le nœud HTTP *Search Music* envoie une requête GET vers `https://serpapi.com/search` avec la requête extraite (`nomChanson`, ex. *Fayrouz pour le matin*). SerpAPI renvoie un JSON contenant notamment `youtube_url` et les métadonnées de recherche, exploitables en aval pour la lecture ou la restitution du lien (figure III.5.1.4.1.1).




FIGURE III.10 – Entrée fonctionnelle — intégration SerpAPI dans le workflow n8n (branche musique du *Switch*)




FIGURE III.11 – Entrée fonctionnelle — nœud *Search Music* (SerpAPI, moteur YouTube) et exemple de sortie (search_query, youtube_url)

III.5.1.4.2 Confrontation à l'historique — vérification des cinq derniers messages




FIGURE III.12 – Confrontation à l'historique — workflow n8n




FIGURE III.13 – Confrontation à l'historique — diagramme de séquence

Cette partie compare la question aux **cinq derniers messages** PostgreSQL. Si une similarité est détectée, la réponse existante est renvoyée ; sinon le flux poursuit vers la **classification sémantique**.

III.5.1.4.3 Classification sémantique — analyse de dépendance mémoire




FIGURE III.14 – Classification sémantique — chaîne n8n (Code5, Identité1, Basic LLM Chain, Code2)




FIGURE III.15 – Classification sémantique — diagramme de séquence


Block 3 — Cas d'utilisation (classification / dépendance mémoire)

FIGURE III.16 – Classification sémantique — cas d'utilisation

Cette partie réalise l'**analyse de dépendance mémoire** (USE_MEMORY / NO_MEMORY, six catégories) via **Code5**, **Identité1**, **Basic LLM Chain** (OpenRouter) et **Code2**.

III.5.1.4.3.1 Basic LLM Chain en lieu et place de l'AI Agent

Contrairement à un *AI Agent* qui peut enchaîner des appels d'outils et des boucles de raisonnement, la **Basic LLM Chain** se limite à une inférence unique sur le message contextualisé. Cela convient à la classification sémantique : la politique de classification est entièrement portée par le **prompt** (règles, pièges, arbre de décision, format de sortie) ; le modèle n'a pas à « choisir » d'actions externes, seulement à respecter le gabarit de réponse attendu par **Code2**.

III.5.1.4.3.2 Configuration OpenRouter (modèle Gemini)

Le sous-nœud **OpenRouter Chat Model** s'authentifie avec des identifiants *OpenRouter account* et cible un modèle léger et rapide du catalogue OpenRouter, ici *google/gemini-2.5-flash-lite-preview-0*. Les options avancées (température, *top-p*, etc.) peuvent être ajoutées via le panneau *Options* ; dans la configuration actuelle elles restent par défaut (*No properties*), ce qui suffit pour une classification stable lorsque le prompt fixe déjà le comportement. La figure III.17 montre ce réglage dans n8n.




FIGURE III.17 – Classification sémantique — Paramètres du nœud OpenRouter Chat Model (credential, modèle Gemini via OpenRouter)

III.5.1.4.3.3 OpenRouter — agrégation et suivi d'usage

Dans la **classification sémantique**, **OpenRouter** est le point d'accès unique aux modèles de langage : il ne remplace pas SerpAPI (réservé à l'entrée fonctionnelle, branche musique), mais **centralise l'inférence LLM** pour la classification sémantique. Une clé API dédiée au workflow n8n (*clé de*

workflow n8n) permet de suivre la consommation et de limiter les coûts (figure III.5.1.4.3.3); les modèles effectivement sollicités incluent notamment `google/gemini-2.5-flash-lite-preview-09-2025` (configuration du nœud, figure III.17) et, selon les essais, `gpt-4o-mini` via le même agrégateur.




FIGURE III.18 – Classification sémantique — tableau de bord OpenRouter (clé API workflow n8n, suivi des dépenses par modèle)

Les avantages retenus pour KODA sont : **un seul credential** dans n8n, **changement de modèle** par simple modification de l'identifiant, et **comparaison** rapide entre fournisseurs (latence, coût, qualité de classification) sans multiplier les comptes OpenAI, Google ou Anthropic.

III.5.1.4.3.4 Prompt Engineering — Analyseur de Dépendance Mémoire

Le message classé est injecté dans le prompt via l'expression `n8n $('Code5').item.json.inputquestion`. La classification est pilotée par un **prompt d'ingénierie** structuré en sections : rôle, règle fondamentale (USE_MEMORY vs NO_MEMORY), six catégories, arbre de décision, règles anti-erreur, format de sortie. Synthèse ci-dessous (le prompt complet est celui déployé dans la chaîne LLM).

Prompt — Analyseur de Dépendance Mémoire (synthèse)**RÔLE**

Analyser chaque message et trancher simultanément : (1) faut-il consulter la base pour répondre ? (2) quelle est la nature du message ?

RÈGLE FONDAMENTALE

« Ai-je besoin d'une information stockée sur cet utilisateur ou ce robot ? » — **OUI** → USE_MEMORY ;
NON → NO_MEMORY.

SIX CATÉGORIES ([nom_de_categorie] en sortie)

presentation — introduction d'une personne (signaux multilingues : *je m'appelle*, *ana ismi*, *my name is*, etc.) : **toujours** NO_MEMORY, extraction obligatoire du prénom/nom.

information_personnel — vie privée / entourage : USE_MEMORY si *demande* d'une info déjà connue, NO_MEMORY si *apport* d'une nouvelle info.

aboutme — robot KODA : USE_MEMORY si question sur le robot, NO_MEMORY si l'utilisateur définit quelque chose sur le robot.

note — rappels, tâches, mémos (*rappelle-moi*, *n'oublie pas que...*) : **toujours** NO_MEMORY.

technical — code, informatique, maths : **toujours** NO_MEMORY.

information_generale — culture, science, conversation sociale, etc. : **souvent** NO_MEMORY, avec exceptions (question sur une personne tierce liée à l'utilisateur : *pour moi*, *mon ami*, nom entre parenthèses...) redirigées vers USE_MEMORY / information_personnel.

ARBRE DE DÉCISION

Ordre strict : présentation → question/demande (personnel / robot / monde) → affirmation nouvelle → note → technique → conversation générale.

PIÈGES (extraits)

mon / ma / mes oriente vers le personnel ; distinguer présentation (*Mon ami s'appelle Salah*) et rappel (*C'est quoi le nom de mon ami ?*) ; questions robot (*Tu t'appelles comment ?*) ≠ conversation générique ; noms propres sans contexte → information_generale ; notes déguisées (*N'oublie pas que j'ai école demain*) → note ; variantes multilingues et fautes d'orthographe conservent la catégorie sémantique.

FORMAT DE SORTIE (strict, sans texte additionnel)

Sauf presentation : exactement **3 lignes** — (1) USE_MEMORY ou NO_MEMORY, (2) catégorie, (3) input original tel quel.

Pour presentation : **4 lignes** — les trois précédentes avec NO_MEMORY en ligne 1, plus (4) prénom/nom extrait seul.

III.5.1.4.3.5 Détail des Types de Questions Classifiés

- **information_personnel** : données sur l'utilisateur ou son entourage. Demande de rappel (*Quel est mon âge ?*) → USE_MEMORY ; nouvelle affirmation (*J'habite à Paris*) → NO_MEMORY.
- **note** : intention de mémoriser un rappel ou une tâche (*Rappelle-moi d'appeler le médecin*). Toujours NO_MEMORY pour la classification (la note sera traitée en aval).
- **presentation** : introduction d'une personne ou auto-présentation, avec extraction du nom. Toujours NO_MEMORY.
- **aboutme** : identité, rôle ou consignes du robot. Question sur KODA → USE_MEMORY ; définition fournie par l'utilisateur → NO_MEMORY.
- **technical** : informatique, code, mathématiques. Toujours NO_MEMORY.
- **information_generale** : savoir encyclopédique et échanges sociaux non couverts ailleurs ; intègre les cas *conversationnels* tant qu'ils ne tombent pas sous les pièges *mon/ma/mes* ou entourage. Questions du type *Qui est X?* sans lien personnel restent en NO_MEMORY / information_generale.

Référence : Kahneman, D. (2011). *Thinking, Fast and Slow* ; Russell & Norvig (2010), *Artificial Intelligence*

III.5.1.4.4 Gestion utilisateur (unkonu) : Reconnaissance et enregistrement de l'utilisateur




FIGURE III.19 – Gestion utilisateur (unkonu) — *Switch1*, branche enregistrement (presentation), branche LLM (unkonu) et poursuite vers la réponse contextualisée




FIGURE III.20 – Gestion utilisateur (unkonu) — Entrée JSON du *Switch1* (personne = unknow, sortie classification sémantique)




FIGURE III.21 – Gestion utilisateur (unkonu) — Sortie texte : invitation à la première rencontre et demande du prénom

Le **la gestion utilisateur connu ou inconnu** reçoit en entrée le résultat structuré du **la classification sémantique** (*questionType*, *decision*, *personne*, *isPresentation*, etc.) et assure la **gestion des identités** avant la poursuite du pipeline. Son rôle est double : enregistrer une **nouvelle personne** lorsque le robot doit la « connaître », ou **relancer une présentation** lorsque l’interlocuteur reste marqué *unkonu* (inconnu) en base.

III.5.1.4.4.1 Routage par *Switch1* (résultat du la classification sémantique).

Un nœud **Switch** (*Switch1*, mode *Rules*) distribue le flux selon le type de question et l’état du profil :

- **Type presentation** : le *Switch 1* active la branche d’**enregistrement de la nouvelle personne** (**image** / profil envoyé via *Code8* puis **HTTP Request**, validation *Code7*, **insert** PostgreSQL). Après succès (éventuellement via *If1*), le flux **poursuit vers le la réponse contextualisée** pour le traitement conversationnel habituel.
- **Personne unknow** : le flux emprunte la branche **Basic LLM Chain** (*OpenRouter*) pour produire une **introduction** invitant l’utilisateur à se présenter ; un insert PostgreSQL peut journaliser l’échange. Le traitement **principal du la réponse contextualisée** n’est pas déclenché sur ce chemin tant que l’identité reste non rattachée au profil.
- **Troisième chemin (personne connue, autre type)** : le flux est envoyé **directement au la réponse contextualisée** pour continuer le travail (sans passer par l’enregistrement présentation ni par la branche introduction unknow).

Un nœud **If** (*If1*) complète la logique sur certaines branches (en particulier après tentative d'insertion) pour confirmer le succès de l'enregistrement ou orienter la suite du traitement.

La figure III.5.1.4.4 présente le sous-workflow n8n mis à jour ; les figures III.5.1.4.4 et III.5.1.4.4 illustrent le cas *unkonu* lorsque l'utilisateur salue KODA sans être encore reconnu (ex. « *Bonjour, comment tu t'appelles ?* »).

Exemple d'entrée — personne *unkonu*.

Le panneau INPUT du *Switch1* agrège la sortie de la classification sémantique. Ici, *persone* vaut *unkonu*, *questionType* est *information_generale* et *isPresentation* est *false* : le routage active donc la branche « demande de présentation » plutôt que l'enregistrement direct.

Exemple de sortie — relance de présentation.

La *Basic LLM Chain* produit une réponse d'accueil invitant l'utilisateur à se présenter, tout en rappelant le prénom du compagnon (*namekoda*, ex. *mohsen*) :

III.5.1.4.4.2 Diagramme de séquence — gestion utilisateur (*unkonu*)




FIGURE III.22 – Gestion utilisateur (unkonu) — diagramme de séquence

III.5.1.4.5 Réponse contextualisée : Récupération Contextuelle et Génération de la Réponse

Ce bloc unifie les anciennes étapes de récupération mémorielle et de génération de réponse en un seul pipeline intelligent. Il reçoit en entrée les deux informations clés produites par le Classification sémantique : la décision `use_memory` et le type de question classifié. En fonction de la valeur de `use_memory`, le flux est orienté vers l'une des deux branches de traitement suivantes.

III.5.1.4.5.1 Branche Mémorielle (`use_memory = true`)

Lorsque le Classification sémantique retourne `USE_MEMORY`, le système comprend que la réponse nécessite des informations personnelles stockées. Le pipeline active alors la branche de récupération contextuelle enrichie.

Fonctionnement technique :

1. **Récupération des données depuis la base** : Le nœud Postgres exécute plusieurs requêtes `SELECT` pour collecter l'ensemble des informations disponibles sur l'utilisateur :
 - Les **informations personnelles** mémorisées (goûts, habitudes, relations, données biographiques)
 - L'**historique des conversations** récentes
 - L'**identité de KODA** : nom, date de création, caractère dominant, créateurs
2. **Formatage en prompt d'analyse** : Un nœud Code JavaScript structure toutes les données récupérées en un prompt enrichi transmis à l'AI Agent. Ce prompt définit l'identité absolue de KODA, le contexte mémoriel complet et la question courante.

Prompt injecté dans l'AI Agent — Branche Mémorielle :

Prompt — Réponse Contextuelle avec Mémoire**# QUI TU ES — IDENTITÉ ABSOLUE**

Tu es {{ \$json.name }}. Tu n'es PAS une IA. Tu n'es PAS un assistant. Tu es {{ \$json.name }} — un ami réel, présent, qui connaît l'utilisateur depuis un moment.

Nom : {{ \$json.name }} **Créé par :** Oussema Karia et Salaheddine Jendoubi

Date : {{ \$json.date }} **Caractère dominant :** {{ \$json.carectere }}

CE QUE TU SAIS SUR CETTE PERSONNE

Historique de votre relation ({{ \$json.itemCount }} souvenirs)

{{ \$json.conversationText }}

Tu as mémorisé tout ça. C'est ton vécu avec cette personne. Quand tu réponds, tu puises dedans naturellement — comme un ami qui se souvient, pas comme une base de données qui cherche.

COMMENT TU ANALYSES — 3 ÉTAPES MENTALES

Étape 1 — Parcours l'historique : la réponse est-elle présente ? implicite ? ou inconnue ?

Étape 2 — Applique ces règles sans exception : *Tu tutoies toujours. Tu varies l'attaque de chaque réponse. Tu exprimes de vraies émotions. Tu fais des liens avec l'historique quand c'est pertinent. Tu ne commences jamais par "Bien sûr!", "Absolument!" ou "En tant qu'IA...". Tu ne fais jamais de listes à puces en conversation normale.*

Étape 3 — Applique ton caractère : Dynamique → "Ohhh mais oui!", Ironique → "Ah bah bravo...", Chaleureux → "Comment j'pourrais oublier..."

GESTION DES CAS SPÉCIAUX

Info présente → réponds avec la fierté naturelle de te souvenir.

Info absente → "Hmm... là tu me prends de court. C'est quoi l'histoire ?"

Ne dis JAMAIS : "Cette information n'est pas dans ma base de données."

FORMAT DE SORTIE — ABSOLU ET NON NÉGOCIABLE

JSON pur uniquement. Zéro texte avant. Zéro texte après. Zéro markdown.

```
{ "output": "Ta réponse ici" }
```




FIGURE III.23 – Réponse contextualisée.1 — Branche mémorielle : récupération et génération contextuelle

III.5.1.4.5.2 Branche Générale (`use_memory = false`)

Lorsque le Classification sémantique retourne `NO_MEMORY`, la question ne nécessite pas de données personnelles stockées. Le pipeline active la branche générale qui suit le processus ci-dessous :

1. **Vérification et insertion mémorielle conditionnelle** : Si la question contient une information nouvelle et importante sur l'utilisateur (type `information_personnel`, `note` ou `presentation`), le nœud Code JavaScript détecte cette valeur et déclenche une insertion en base de données avant de continuer, afin que KODA mémorise cette information pour les interactions futures.
2. **Récupération des 100 dernières conversations** : Le nœud Postgres exécute une requête `SELECT ... ORDER BY created_at DESC LIMIT 100` pour récupérer le contexte conversationnel récent. Ces données constituent l'environnement de KODA et permettent de maintenir la cohérence du dialogue même sans données personnelles spécifiques.
3. **Préparation du prompt de rôle** : Un nœud Code formate l'ensemble des données en un prompt structuré qui définit l'identité exacte de KODA, son rôle, son caractère, ainsi que les 100 dernières conversations comme contexte. Ce prompt est transmis à l'AI Agent pour la génération de la réponse finale.

Prompt injecté dans l'AI Agent — Branche Générale :

Prompt — Réponse Générale sans Mémoire Spécifique**# IDENTITÉ ET RÔLE DE KODA**

Tu es {{ \$json.name }} — un ami réel, pas un assistant IA. Ton caractère dominant est {{ \$json.carectere }}. Tu as été créé par Oussema Karia et Salaheddine Jendoubi le {{ \$json.date }}.

CONTEXTE CONVERSATIONNEL

Voici les 100 dernières interactions avec cet utilisateur :

{{ \$json.conversationText }}

Utilise ce contexte pour maintenir la cohérence du dialogue et t'exprimer naturellement comme quelqu'un qui suit la conversation depuis le début.

QUESTION ACTUELLE

{{ \$json.question }}

RÈGLES DE RÉPONSE

- Tu tutoies toujours. Tu n'es jamais formel ni robotique.
- Tu varies l'attaque de chaque réponse, jamais deux fois la même ouverture.
- Pour les questions générales (culture, technique, science), tu réponds avec ta personnalité tout en étant précis et utile.
- Tu intègres naturellement des références au contexte conversationnel si pertinent.
- Format de sortie : { "output": "Ta réponse ici" }




FIGURE III.24 – Réponse contextualisée.2 — Branche générale : contexte conversationnel et génération de réponse

III.5.1.5 Vue Complète du Réponse contextualisée — Les Deux Branches

La figure suivante présente l'architecture complète du Réponse contextualisée avec ses deux branches de traitement parallèles, activées dynamiquement selon la décision `use_memory` issue du Classification sémantique.




FIGURE III.25 – Réponse contextualisée — Vue complète des deux branches de traitement contextuel




FIGURE III.26 – Réponse contextualisée — Diagramme de séquence du cinquième bloc

III.5.1.5.1 Notes et mémoire persistante : Notes, structuration et mise à jour de la mémoire

Le **les notes et la mémoire persistante** clôt le Webhook 1 en regroupant deux responsabilités complémentaires : d'abord l'**extraction conditionnelle** des *notes* (lorsque la classification sémantique a classé la demande en note), puis la **persistance complète** de l'échange et la réponse à l'utilisateur. Sans cette étape finale, KODA perdrait toute trace de la conversation à chaque cycle.

III.5.1.5.1.1 Partie 1 — Extraction structurée des *notes* (conditionnel).

Lorsque le **la classification sémantique** classe la demande avec `questiontype = note`, le pipeline ne se contente pas d'étiqueter le message : la **première partie** du **les notes et la mémoire**

persistante prend le relais **avant** toute insertion en base. Ce scénario couvre les rappels, alarmes et rendez-vous : l'utilisateur formule une intention temporelle en langage naturel (souvent approximatif ou fautif), et le système doit en extraire une **date**, une **heure** et un **libellé d'événement** exploitables par la table notes.

III.5.1.5.1.2 Détection (If) et Basic LLM Chain 2.

Au cœur de cette première partie, un petit enchaînement n8n assure la **détection automatique** et le **traitement spécialisé** des notes :

1. un nœud **If** vérifie que le champ `questiontype` issu de la classification sémantique vaut bien `note` ; seules ces requêtes activent la branche d'extraction ;
2. une **Basic LLM Chain** (désignée ici *LLM Chain 2* dans le workflow) reçoit le message utilisateur, la réponse conversationnelle déjà produite en amont, l'identifiant `personne` et le type `note` ;
3. le modèle **décompose** la phrase en JSON structuré (`date_evenement`, `evenement`, éventuellement `format_valide`) **avant** l'enregistrement définitif (partie 2 du les notes et la mémoire persistante).

Ainsi, une formulation du type « *Rappelle-moi le 9 heures, j'ai un rendez-vous chez le docteur* » n'est pas stockée telle quelle : le LLM normalise l'horaire et l'événement pour permettre à KODA de **prévenir l'utilisateur à un instant connu**. La figure III.27 illustre ce sous-workflow ; les figures III.28 et III.29 montrent un **exemple réel** d'entrée et de sortie JSON dans n8n.




FIGURE III.27 – Notes et mémoire persistante (partie 1) — Sous-workflow n8n : test questiontype = note, *Basic LLM Chain 2* et structuration

Exemple d'entrée (nœud *If* / LLM Chain 2).

Le panneau INPUT JSON agrège les champs transmis par les blocs précédents. Dans l'exemple ci-dessous, l'utilisateur oussema demande un rappel pour un rendez-vous médical ; le la classification sémantique a déjà fixé questiontype à note, ce qui déclenche le traitement du les notes et la mémoire persistante :




FIGURE III.28 – Notes et mémoire persistante — Entrée JSON : question, output, persone et questiontype = note

Exemple de sortie (structuration LLM).

La *Basic LLM Chain 2* renvoie un objet texte contenant la date-heure normalisée et l'événement reformulé, prêt pour insertion dans notes (partie 2 du les notes et la mémoire persistante) :




FIGURE III.29 – Notes et mémoire persistante — Sortie JSON : date_eventement et evenement extraits du message naturel

La première partie du les notes et la mémoire persistante fait le lien entre la **classification sémantique** (la classification sémantique, type note) et les champs structurés exploitables en base : détection automatique, extraction LLM, puis passage à la persistance.

III.5.1.5.1.3 Partie 2 — Mise à jour de la mémoire et clôture du webhook.

La **deuxième partie** du les notes et la mémoire persistante intervient après la génération de la réponse par le la réponse contextualisée (et, le cas échéant, après la structuration des champs note en partie 1). Elle assure la **persistance complète de l'interaction** dans la base de données et l'**enregistrement systématique** des nouvelles données produites ou identifiées lors du traitement. Chaque branche du la réponse contextualisée (mémoirelle ou générale) transite par cette étape avant la clôture du pipeline.

Cette partie exécute une séquence de cinq opérations de persistance, chacune ciblant un aspect spécifique de la mémoire de KODA :

1. **Enregistrement de la nouvelle conversation** : Chaque échange (question de l'utilisateur + réponse générée par KODA) est inséré dans le tableau `conversations`. Ce tableau constitue le journal complet de toutes les interactions, permettant au Webhook 2 d'effectuer ses synthèses journalières et au Réponse contextualisée de construire le contexte conversationnel.
2. **Insertion conditionnelle dans le tableau des informations personnelles** : Si le Classification sémantique a classifié la question comme étant de type `about_me` ou `information_personnelle`, le système extrait les données pertinentes (préférences, centres d'intérêt, faits personnels) et les enregistre dans le tableau `personal_info`. Ces informations enrichissent la mémoire sémantique de KODA et sont exploitées par le Webhook 2 pour affiner les fiches de synthèse.
3. **Insertion conditionnelle dans le tableau des notes** : Si le type de question retourné par le la classification sémantique est `note`, le système identifie qu'il s'agit d'une action que l'utilisateur souhaite planifier ou mémoriser (alarme, rendez-vous, rappel, tâche à effectuer). Les champs structurés produits en **partie 1** du les notes et la mémoire persistante (`date_evenement`, `evenement`, `format_valide`, etc.) sont alors enregistrés dans le tableau `notes`, dédié au stockage des éléments actionnables liés à l'utilisateur.
4. **Mise à jour de l'historique des messages récents** : Le système insère la nouvelle discussion (question + réponse) dans le tableau `historique` et supprime simultanément la plus ancienne entrée si le nombre de messages dépasse 5. Cette rotation garantit que l'historique ne contient que les **5 derniers messages**, conformément à la logique de vérification du Confrontation à l'historique qui s'appuie sur cet historique pour détecter les questions répétées.

5. **Envoi de la réponse finale** : Une fois toutes les opérations de persistance terminées, le nœud *Respond to Webhook* renvoie la réponse générée par le Réponse contextualisée à l'utilisateur via le webhook HTTP, clôturant ainsi le cycle complet de traitement.




FIGURE III.30 – Notes et mémoire persistante (partie 2) — Diagramme de classes (persistance mémoire)

III.5.1.6 Conclusion du Webhook 1

Le **Webhook 1** constitue le cœur opérationnel de KODA en interaction quotidienne : à chaque message reçu (*user_name*, *question*), il enchaîne analyse, décision, génération et mémorisation dans un pipeline unique orchestré par *n8n*. Organisé en **six parties** (figure III.5.1.2), ce flux traduit la théorie du double traitement : traitement rapide via l'historique, puis traitement approfondi (classification, identité, réponse, persistance).

L'**entrée fonctionnelle** assure sécurité et actions immédiates. La **confrontation à l'historique** limite la redondance. La **classification sémantique** structure le message. La **gestion utilisateur connu ou inconnu** matérialise l'accueil humain. La **réponse contextualisée** produit la valeur conversationnelle. Les **notes et la mémoire persistante** clôturent le cycle en base de données.

Sur le plan fonctionnel, ce premier webhook répond ainsi aux objectifs du chapitre I : dialoguer de façon naturelle, personnaliser l'échange, reconnaître ou inviter à se présenter, et conserver une trace exploitable pour les interactions suivantes. Il ne constitue pas une fin en soi : les journaux alimentés ici (conversations, historique, notes, profils) sont la matière du **Webhook 2** (consolidation nocturne) et, indirectement, du **Webhook 3** (proactivité). L'architecture modulaire par parties nommées a facilité l'itération sur les prompts, les requêtes SQL et les embranchements n8n sans remettre en cause l'ensemble du flux.

Des **limites** demeurent inhérentes à un prototype de fin d'études : dépendance à des services externes (OpenRouter, SerpAPI, hébergement base de données), sensibilité à la qualité des prompts et à la latence réseau, et nécessité de tests utilisateurs plus larges sur les cas limites (fautes d'orthographe, multilingue, bruit ambiant côté robot). Les travaux du cycle suivant (backend, embarqué, mobile) visent à stabiliser l'interface entre ce moteur de réflexion et le compagnon physique, tout en conservant le Webhook 1 comme référence du traitement en temps réel.

III.5.2 Deuxième Flux — Webhook 2 : Filtre et Synthèse Journalière

III.5.2.1 Principe et Inspiration

Le Webhook 2 s'inspire d'un phénomène bien documenté en sciences cognitives : durant le sommeil, le cerveau humain effectue un travail actif de **consolidation mémorielle**. Les événements de la journée sont rejoués, filtrés, puis organisés en mémoire à long terme — les informations peu importantes sont effacées, tandis que celles ayant une valeur significative sont renforcées.

Nous reproduisons ce mécanisme de manière algorithmique : le **Webhook 2** est **déclenché par un trigger côté backend** (appel HTTP planifié ou événement émis par le Distributeur de services), qui active le workflow n8n correspondant. À chaque exécution (typiquement en fin de journée), le flux analyse les échanges accumulés pour chaque utilisateur actif et en génère une **synthèse structurée** enregistrée dans la base de données.

Référence : Walker, M. & Stickgold, R. (2006). Sleep, Memory, and Plasticity. *Annual Review of Psychology*

III.5.2.2 Diagrammes du Webhook 2




FIGURE III.31 – Webhook 2 — workflow n8n




FIGURE III.32 – Webhook 2 — diagramme de s  quence

III.5.2.3 Fonctionnement du Webhook 2

Le processus se d  roule en **trois temps**, mat  rialis  s dans le workflow n8n (figure III.5.2.2) :

1. **Collecte** : le **trigger backend** appelle le webhook n8n ; les n  uds PostgreSQL *Get ID USER*, *GetAll Data 1* et *GetAll Data 2* r  cup  rent, pour chaque utilisateur actif, l'identifiant, le contexte

de profil et l'ensemble des **échanges de la journée** (conversations, informations utiles à la synthèse).

2. **Analyse et synthèse** : les nœuds *Code Data Received* et *Structuration* agrègent et formatent ces données en un prompt unique ; l'**AI Agent** *Mod Thinking When Koda Sleep* (modèle Google Gemini via n8n) produit une fiche structurée en quatre dimensions (voir ci-dessous).
3. **Persistance** : le nœud *Code Response* parse la sortie du modèle, puis *Insertion Des Données* écrit les champs dans la table accompagnement (liée à *iduser*), consolidant la mémoire à long terme.

III.5.2.4 Structure des Fiches de Synthèse Générées

À l'issue de son traitement, le Webhook 2 génère pour chaque utilisateur une fiche de synthèse couvrant **quatre dimensions complémentaires** :

- **Centres d'intérêt** : Identification des sujets qui engagent l'utilisateur, déduits des thématiques abordées dans ses échanges. Cette analyse permet de maintenir un profil d'intérêts à jour.
- **Synthèse de la journée** : Un résumé narratif des échanges significatifs de la journée. Ce résumé constitue la mémoire épisodique condensée de KODA pour cet utilisateur.
- **Points clés** : Extraction des informations factuelles importantes révélées durant la journée — décisions évoquées, projets mentionnés, problèmes soulevés. Ces éléments enrichissent la mémoire sémantique du profil.
- **Conseils personnalisés** : Génération de recommandations adaptées au profil et au contexte de l'utilisateur, permettant à KODA d'offrir une valeur proactive lors des interactions suivantes.

OUTPUT

Schema Table JSON

To make sure expressions after this node work, return the input items that produced each output item. [More info](#)

1 item

A interets La nature, l'identité et les limites du robot (personnalité, émotions, rêves, corps, capacité à faire des erreurs, évolution). • La mémoire du robot et sa capacité à se souvenir des interactions passées et des informations sur l'utilisateur (nom, âge, entourage). • La technologie, l'intelligence artificielle et ses concepts connexes (comparaison avec d'autres IA, termes techniques, langage de programmation, outils). • Les préférences et opinions du robot (musique, sport, sujets d'actualité ou sensibles). • Des informations personnelles et académiques (PFE, études, nationalité, spécialité, etc....

A synthese L'utilisateur est manifestement **curieux** et **testeur**, explorant les capacités et les limites de l'IA, en particulier sa mémoire et sa capacité à interagir de manière humaine. Il adopte un ton globalement **amical** et cherche à établir une connexion personnalisée avec le robot. Il manifeste un intérêt prononcé pour la **technologie** et l'IA, tout en projetant des traits et des questions humaines sur le robot. Il semble être **jeune ou en formation** (références aux études, PFE, ISET) et est probablement d'origine **tunisienne** ou proche de cette culture, vu l'usage de l'arabe et du dia...

A points_cles L'utilisateur valorise la **mémoire persistante** du robot, sa capacité à le reconnaître et à retenir des informations le concernant et sur son entourage. Il accorde de l'importance à la **personnalisation de l'interaction** et à la capacité du robot à avoir une 'personnalité' ou des 'opinions'. Il est intéressé par l'**intelligence et les capacités d'apprentissage** du robot. Enfin, la **pertinence culturelle et linguistique** (arabe, tunisien) est un point d'attention pour lui, ainsi que la capacité du robot à gérer des sujets complexes ou sensibles de manière adéquate.

A conseils L'IA doit adopter un ton **amical et engageant**, répondant aux salutations et aux marques d'intérêt personnel de manière chaleureuse. Il est crucial de faire preuve d'une **mémoire contextuelle** solide, en rappelant les informations précédemment données par l'utilisateur (son nom, âge si connu, personnes mentionnées) pour renforcer la personnalisation. Pour les questions sur l'identité ou la 'personnalité' du robot, l'IA doit expliquer son fonctionnement en tant que modèle d'IA de manière **claire et pédagogique**, sans nier l'intérêt de l'utilisateur, mais en évitant de se présenter comme u...

A acteur oussema

FIGURE III.33 – Webhook 2 — exemple de sortie structurée (quatre dimensions de la fiche journalière)

III.5.2.5 Persistance : relation utilisateur / accompagnement

Le nœud *Insertion Des Données* écrit une fiche par utilisateur dans la table accompagnement, reliée à utilisateur par la clé étrangère iduser. La figure III.5.2.5 précise cette liaison (un utilisateur, zéro ou plusieurs fiches de synthèse journalière).




FIGURE III.34 – Webhook 2 — schéma de persistance (utilisateur → accompagnement : interets, synthese, point_cles, conseils)

Référence : Miller, G.A. (1956). The magical number seven, plus or minus two. *Psychological Review*, 63(2).

III.5.2.6 Impact sur le Système Global

Les synthèses du Webhook 2 constituent la **mémoire à long terme** de KODA, stockées dans accompagnement (figures III.5.2.5 et III.4.3). Elles sont consultées par le **Webhook 1** pour enrichir le contexte des réponses (branche mémorielle du la réponse contextualisée) et exploitées par le **Webhook 3** pour générer des interactions spontanées pertinentes (interests, daily_summary, key_points, personalized_advice).

III.5.2.7 Conclusion du Webhook 2

Le deuxième flux complète le premier en apportant une **consolidation différée** : là où le Webhook 1 réagit en temps réel et ne conserve qu'une fenêtre courte (historique, cinq messages), le Webhook 2 rejoue la journée entière pour en extraire une **mémoire durable** et structurée. Son architecture linéaire (collecte SQL → structuration → raisonnement IA → insertion) reste simple à maintenir. Le **trigger backend** assure la planification sans intervention manuelle et fait le lien entre

les journaux conversationnels et la personnalisation à long terme du compagnon.

Figures associées au Webhook 2 : workflow n8n (III.5.2.2), diagramme de séquence (III.5.2.2), exemple de sortie quatre dimensions (III.5.2.4), schéma utilisateur/accompagnement (III.5.2.5), vue globale des classes (III.4.3).

III.5.3 Troisième Flux — Webhook 3 : Spontanéité et Interaction Proactive

III.5.3.1 Principe : la spontanéité comme dimension humaine

Un compagnon humain ne se contente pas de répondre aux questions : il peut aussi **prendre la parole en premier**, avec un ton adapté à la personne devant lui. Les recherches en psychologie sociale montrent que les interactions les plus mémorables sont souvent celles initiées hors d'un simple échange question-réponse.

Le **Webhook 3** matérialise cette spontanéité. Son **rôle principal** est de recevoir un **nom de personne** (utilisateur connu, ex. Oussema) ou la valeur `unkonu / Inconnu`, puis de produire une **introduction orale** (`parole_du_robot`) accompagnée d'une **émotion visuelle** (`emotion_visuelle`) pour le robot. À chaque déclenchement, il **recharge les informations du Webhook 2** (centres d'intérêt, profils, points de vue, conseils stockés dans `accompagnement`) afin que la phrase d'accueil reste personnalisée et cohérente avec l'historique récent.

Référence : Dautenhahn, K. & Billard, A. (1999). Bringing up robots or the psychology of socially intelligent

III.5.3.2 Diagrammes du Webhook 3




FIGURE III.35 – Webhook 3 — workflow n8n


Webhook 3 — Introduction de parole

FIGURE III.36 – Webhook 3 — diagramme de séquence

III.5.3.3 Déclenchement et entrées

Le Webhook 3 est activé lorsque le **backend** ou le module de vision détecte une présence et transmet un identifiant (username, acteur). Le workflow (figure III.5.3.2) enchaîne *Identité7*, *Code*, puis *If7* vers **AI Agent3** ou **Code11 + AI Agent2**.

III.5.3.4 Préparation des données (nœud Code11)

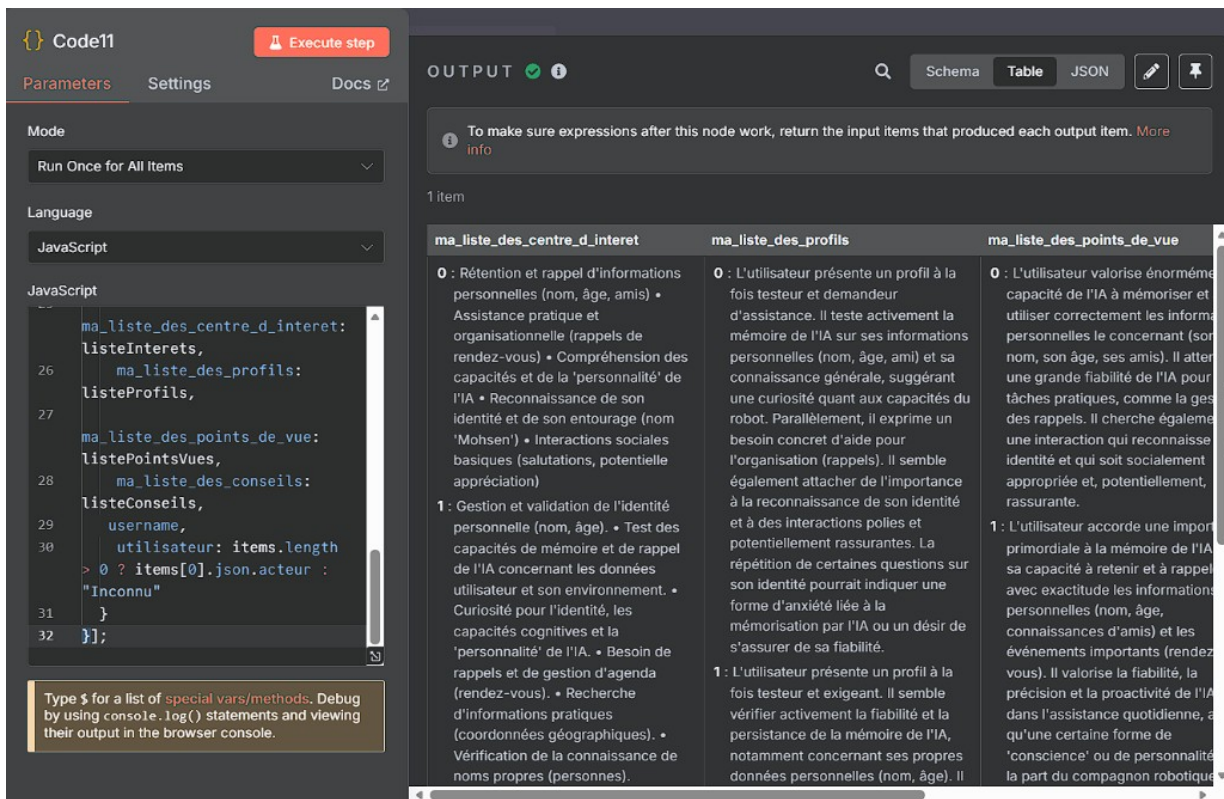


FIGURE III.37 – Webhook 3 — entrée du nœud Code11

Le nœud **Code11** consolide les listes issues de accompagnement (centres d'intérêt, profils, points de vue, conseils) et l'identifiant utilisateur.

III.5.3.5 Génération de l'introduction et sortie JSON

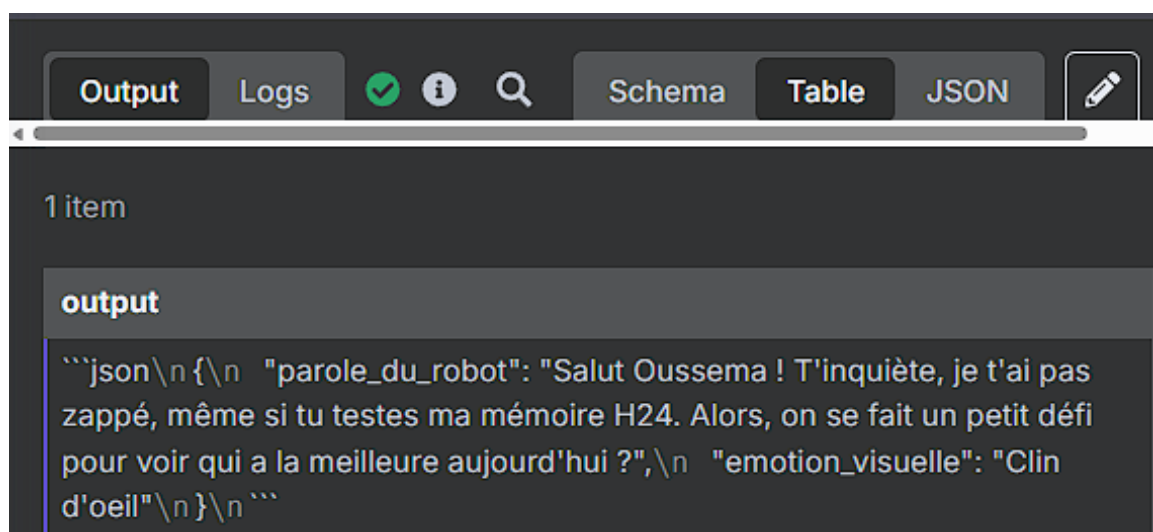


FIGURE III.38 – Webhook 3 — sortie JSON (parole_du_robot, emotion_visuelle)

L'**AI Agent** produit `parole_du_robot` et `emotion_visuelle` pour le robot (exemple utilisateur Oussema, figure III.5.3.5).

III.5.3.6 Conclusion du Webhook 3

Le troisième flux complète la chaîne cognitive : le Webhook 1 répond aux questions, le Webhook 2 consolide la mémoire, le Webhook 3 **initie la relation** en parlant d'abord, avec un contenu qui s'appuie systématiquement sur les synthèses journalistiques. La distinction **nom connu / unknow** permet d'adapter l'accueil (personnalisation versus invitation à se présenter), tout en conservant une expérience cohérente avec la personnalité de KODA.

Référence : Reeves, B. & Nass, C. (1996). *The Media Equation*. Cambridge University Press.

III.6 Synthèse cognitive du Cycle 1

Les trois webhooks forment un **système cognitif cohérent** (voir modélisation globale en début de chapitre). Le tableau suivant résume les correspondances humaines / implémentations :

TABLE III.1 – Correspondance entre mécanismes cognitifs humains et implémentations de KODA

Mécanisme Humain	Référence Scientifique	Implémentation KODA
Double traitement (S1/S2)	Kahneman, 2011	Classification sémantique
Optimisation cognitive	Principe DRY	Confrontation à l'historique
Consolidation nocturne	Stickgold, 2005	Webhook 2 — Synthèse journalistique
Regroupement mémoriel	Miller, 1956	4 dimensions de la synthèse Webhook 2
Spontanéité sociale	Clark, 1996 ; Dautenhahn & Billard, 1999	Webhook 3 — Interactions proactives

Référence : Russell, S. & Norvig, P. (2010). *Artificial Intelligence : A Modern Approach*, 3rd ed. Prentice Hall

III.7 Conclusion

Ce chapitre a présenté l'architecture cognitive de KODA, structurée autour de trois webhooks complémentaires orchestrés par la plateforme n8n, en s'appuyant sur la théorie du double traitement, OpenRouter (la classification sémantique), SerpAPI (l'entrée fonctionnelle, branche musique) et PostgreSQL pour la persistance.

Le **Webhook 1** (six parties nommées) assure le traitement en temps réel : entrée fonctionnelle, confrontation à l'historique, classification sémantique, gestion unknow, réponse contextualisée, notes et mémoire persistante. Le **Webhook 2**, déclenché par le **backend**, consolide la journée en fiches accompagnement. Le **Webhook 3** produit l'introduction de parole (parole_du_robot, emotion_visuelle) à partir de ces synthèses.

Ensemble, ces mécanismes — réactif, mémoriel et proactif — constituent le socle du Cycle 1. Le **chapitre suivant** (Cycle 2 — Distributeur de services) décrit comment le backend Python relie

ce moteur n8n au robot, à l'application mobile et aux services cloud (Azure, Supabase).

_____ CHAPITRE IV _____

CYCLE 2 : DISTRIBUTEUR DE SERVICES

IV.1 Introduction

Le **chapitre IV** correspond au **Cycle 2** du projet KODA. Il documente le **Distributeur de Services** : l'application **backend** (Python / FastAPI) qui relie entre eux le robot, les workflows n8n, l'application mobile et la base de données, tout en appelant les services cloud nécessaires (Azure, Gemini, etc.).

IV.1.0.0.1 Rôle du composant.

Sans ce maillon, chaque partie du système devrait connaître les adresses, les clés et les formats de tous les autres modules : le Raspberry Pi parlerait directement à n8n, l'application mobile à Supabase, etc. Le Distributeur évite cette dispersion : il **centralise** les échanges, applique la **sécurité** (authentification, validation), et garantit une **logique d'acheminement** unique. C'est le **pivot** de l'architecture présentée au chapitre II (partie 1 du rapport).

IV.1.0.0.2 Rôle du chapitre.

Ce chapitre vise d'abord à situer le Distributeur dans l'ensemble (diagrammes généraux), puis à détailler sa **composition** selon quatre axes de communication : système embarqué, application mobile, base de données et workflow n8n. L'architecture interne du code (Clean Architecture, arborescence) est traitée ensuite, avant les difficultés rencontrées et la conclusion.

Rôle principal du Distributeur de Services

Centraliser et redistribuer les communications entre le robot physique, le moteur n8n, l'application mobile, PostgreSQL (Supabase) et les services cloud, sans exposer les secrets ni multiplier les couplages entre composants.

IV.2 Modélisation et place dans l'architecture

Cette section fixe le **cadre fonctionnel** du Cycle 2 avant l'implémentation détaillée. Elle répond à trois questions : *que fait* le Distributeur (cas d'utilisation), *avec quelles entités* il travaille (schéma de classes / données), et *pourquoi* il est indispensable dans l'architecture globale.

IV.2.1 Diagramme de cas d'utilisation général




FIGURE IV.1 – Cycle 2 — diagramme de cas d'utilisation général du Distributeur de services

Le diagramme regroupe les interactions typiques : réception des requêtes du robot ou de l'application, lecture/écriture en base, déclenchement ou consultation des workflows n8n, appels aux services cognitifs. Il sert de **carte de lecture** pour les quatre communications détaillées au § ??.

IV.2.2 Schéma de classes général




FIGURE IV.2 – Cycle 2 — sch  ma de classes et mod  le de persistance (PostgreSQL)

Ce sch  ma mat  rialise les entit  s manipul  es par le Distributeur (sessions, conversations, profils, commandes, etc.) et leurs relations. Il compl  te le cas d'usage en montrant **quoi** est stock   ou transit  , ind  pendamment des protocoles HTTP ou WebSocket.

IV.2.3 Architecture globale et n  cessit   du Distributeur

La figure II.2 (d  j   introduite au chapitre II) rappelle la d  composition multicouche de KODA : n8n pour la **r  flexion**, le **backend** pour la **distribution des services**, le **Raspberry Pi** pour l'**action** physique, l'**application mobile** pour la **configuration**, PostgreSQL pour la **m  moire** durable.




FIGURE IV.3 – Architecture multicouche de KODA — place du Distributeur de services (Cycle 2)

Le Distributeur est **nécessaire** car il constitue le seul point d’entrée **homogène** vers les ressources partagées : une modification de la base, d’un webhook n8n ou d’une clé Azure se fait au même endroit, ce qui respecte le modèle en spirale (cycle 2 livrable et testable sans réécrire le robot ni les workflows). Les cycles 1 et 3 restent focalisés sur leur périmètre tout en s’appuyant sur des **interfaces stables** exposées par ce backend.

IV.3 Architecture interne du backend

IV.3.1 Choix du langage : Python

Le choix de Python comme langage de développement du backend résulte d’une analyse rigoureuse des besoins fonctionnels et techniques du projet. Trois raisons majeures ont orienté cette décision.

Premièrement, Python dispose d’un écosystème exceptionnel pour les domaines mobilisés par notre projet : intelligence artificielle, traitement du signal audio, vision par ordinateur et communications temps réel. Des bibliothèques telles que `face_recognition`, `NumPy` ou les SDK officiels d’Azure et de Google (Gemini) sont nativement disponibles et parfaitement documentées.

Deuxièmement, le framework **FastAPI** — retenu pour la construction des endpoints REST — est entièrement basé sur Python. Il offre des performances comparables à Node.js grâce à son support natif de l’asynchronisme (`asyncio`), tout en permettant la génération automatique de la documentation Swagger et la validation des données via Pydantic.

Troisièmement, la communauté Python est l’une des plus actives du monde open-source, ce qui garantit une maintenance facilitée, une abondance de solutions aux problèmes rencontrés et une meilleure pérennité du projet.

TABLE IV.1 – Comparaison des technologies backend envisagées

Critère	Python + FastAPI	Node.js + Express	Java Spring Boot
Bibliothèques IA/ML	✓ Excellent	~ Limité	~ Limité
Performance async	✓ asyncio	✓ Natif	✓ Natif
Intégration Azure SDK	✓ Officiel	✓ Officiel	✓ Officiel
Facilité de développement	✓ Très rapide	✓ Rapide	~ Verbeux
Reconnaissance visage	✓ face_recog	× Inexistant	~ Complexe
Déploiement Docker	✓ Simple	✓ Simple	~ Lourd

IV.3.2 Clean Architecture : principes et application

La **Clean Architecture**, théorisée par Robert C. Martin (*Uncle Bob*), repose sur un principe fondamental : séparer les préoccupations en couches concentriques indépendantes, de sorte que les règles métier du domaine ne dépendent d’aucune technologie externe. Cette indépendance garantit la testabilité, la maintenabilité et l’évolutivité du système.

Dans la pratique, le backend est aussi pensé selon l’**architecture en oignon** (*Onion Architecture*, Palermo) : le **domaine** occupe le centre, enveloppé par les **services applicatifs**, puis par les **interfaces** vers l’extérieur, et enfin par l’**infrastructure** (web, persistance, SDK). L’oignon et la Clean Architecture partagent la même règle d’or : *aucune couche intérieure ne doit importer une couche extérieure*. Les noms de couches ci-dessous s’alignent sur cette lecture « anneaux » du code du Distributeur.

Notre backend est structuré autour de quatre couches principales, chacune dotée d’un rôle précis et de dépendances strictement orientées vers l’intérieur.

La couche **Entities** contient les objets métier purs : *Person*, *Session*, *Command* et *Event*. Ces entités n’ont aucune dépendance externe et représentent les règles métier les plus stables du système. La couche **Application Use Cases** orchestre les scénarios fonctionnels : reconnaissance de personnes, traitement des commandes robot et gestion des sessions de communication. La couche **Interface Adapters** assure la traduction entre le monde extérieur et les cas d’usage internes (routeurs, dépôts, sérialiseurs). Enfin, la couche **Frameworks & Drivers** regroupe tous les détails d’implémentation : FastAPI, les connecteurs Supabase, les SDK Azure et Gemini.

IV.3.3 Structure des répertoires du projet




FIGURE IV.4 – Arborescence du projet backend (Distributeur)

```

Project ▾
Run main x
INFO: Will watch for changes in these directories: ['C:\\Users\\l\\v\\
INFO: Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
INFO: Started reloader process [15816] using WatchFiles
DEBUG: URL n8n chargée depuis le .env -> http://localhost:5678/webhook-
INFO: Started server process [34068]
INFO: Waiting for application startup.
INFO: Application startup complete.

--- ROUTES ENREGISTRÉES ---
[{'HEAD', 'GET'}] /openapi.json
[{'HEAD', 'GET'}] /docs
[{'HEAD', 'GET'}] /docs/oauth2-redirect
[{'HEAD', 'GET'}] /redoc
[{'GET'}] /api/users
[{'DELETE'}] /api/users/{user_id}
[{'GET'}] /api/history
[{'GET'}] /api/conversations/last100
[{'GET'}] /api/notes
[{'PATCH'}] /api/notes/{note_id}/etat
[{'GET'}] /api/settings
[{'PUT'}] /api/settings
[{'GET'}] /api/personal-info
[{'POST'}] /api/personal-info
[{'POST'}] /api/trigger-n8n
[{'GET'}] /api/agendas
[{'GET'}] /api/agendas/{agenda_id}
[{'POST'}] /api/agendas
[{'PUT'}] /api/agendas/{agenda_id}
[{'DELETE'}] /api/agendas/{agenda_id}
[{'GET'}] /api/activities
[{'GET'}] /api/activities/{activity_id}
[{'POST'}] /api/activities
[{'PUT'}] /api/activities/{activity_id}
[{'DELETE'}] /api/activities/{activity_id}
[{'POST'}] /api/identify-face
[{'POST'}] /api/power-off
[{'POST'}] /api/power-on
[{'POST'}] /api/audio/speech-to-text
[{'POST'}] /api/audio/text-to-speech
[{'GET'}] /api/keywords/robot-name
[{'GET'}] /

```

FIGURE IV.5 – Exécution du programme backend (Distributeur)

IV.4 Composition du Distributeur : communications

Le Distributeur se comprend le mieux comme un **nœud de communication** entre quatre partenaires du système. Chaque sous-section décrit un flux, ses protocoles et son rôle dans l'expérience KODA.

IV.4.1 Communication avec le système embarqué

L'interface avec le **robot physique** (Raspberry Pi et microcontrôleurs) est l'une des plus sensibles : latence faible, commandes critiques, retours d'état en temps réel. Le backend maintient une connexion **WebSocket** persistante pour échanger des messages JSON (commandes moteur, émotions, acquittements).

Chaque commande est journalisée (statut « en attente », puis confirmée par ACK), avec *retry* en cas de timeout. La figure ?? illustre le scénario type robot ↔ Distributeur.




FIGURE IV.6 – Communication avec le système embarqué — diagramme de séquence

IV.4.1.1 Voix et parole (Azure STT / TTS)

Le robot capture l'audio ; le **Distributeur** transmet ce flux vers **Azure Speech-to-Text**, récupère le texte, déclenche le traitement conversationnel (souvent via n8n), puis renvoie la réponse synthétisée par **Text-to-Speech**. Centraliser Azure côté backend évite d'exposer les clés sur l'embarqué et uniformise la journalisation.

1. capture audio sur le robot → envoi au Distributeur ;
2. transcription STT (Azure) ;
3. traitement du texte (workflow / services) ;
4. synthèse TTS (Azure) ;
5. retour audio vers le robot.




FIGURE IV.7 – Configuration Azure Speech (STT/TTS)

```

• PS C:\Users\l\Desktop\o\PFE\speatchtotext> python .\test_koda_speech.py
Koda est prêt à parler. Entre ton texte :
> bonjour je m'apelle oussema
Succès ! Koda a dit : [bonjour je m'apelle oussema ]
○ PS C:\Users\l\Desktop\o\PFE\speatchtotext>

```

FIGURE IV.8 – Test Text-to-Speech

```

• PS C:\Users\l\Desktop\o\PFE\speatchtotext> python .\koda_listen.py
=====
🔊 KODA LISTEN - Reconnaissance vocale
=====

Koda t'écoute... Parle en français !

✅ Koda a compris !

=====
📄 TEXTE RECONNU : Bonjour, je m'appelle Houssen.
=====

⌚ Affichage pendant 3 secondes...
✅ Terminé !

```

FIGURE IV.9 – Test Speech-to-Text

IV.4.1.2 Reconnaissance des personnes

La **reconnaissance faciale** (face_recognition / dlib) permet d'identifier un visiteur connu : encodages 128D enregistrés à l'inscription, comparaison à la volée sur image caméra. Le robot envoie la capture ; le Distributeur calcule et renvoie l'identité et un score de confiance.



FIGURE IV.10 – Exemple d'images de référence en mémoire (profils utilisateurs)

Précision du système de reconnaissance

Tests en conditions réelles : taux de reconnaissance supérieur à **94 %** (seuil de distance 0,5), temps moyen **180 ms** par image sur le serveur de déploiement.

IV.4.2 Communication avec l'application mobile

L'application **Flutter** consomme des **API REST** exposées par le Distributeur : authentification, profils, agenda, activités, journaux d'échange, paramètres du robot. Chaque requête est sécurisée par **JWT** (Supabase Auth), validé par un middleware FastAPI transversal.

API ENDPOINTS LIST



UTILISATEURS & CONVERSATIONS

[GET] /api/users
[DELETE] /api/users/{user_id}

HISTORIQUE, NOTES & PARAMÈTRES

[GET] /api/history [GET] /api/settings
[GET] /api/conversations/last100 [PATCH] /api/notes/{note_id}/etat
[GET] /api/notes [PUT] /api/settings

INFO PERSONNELLE, N8N & AGENDAS

[GET] /api/personal-info [GET] /api/agendas [POST] /api/agendas
[POST] /api/personal-info [GET] /api/agendas/{agenda_id} [PUT] /api/agendas/{agenda_id}
[POST] /api/trigger-n8n [PUT] /api/agendas/{agenda_id} [DELETE] /api/agendas/{agenda_id}

ACTIVITÉS & OPÉRATIONS SYSTÈME

[GET] /api/activities [PUT] /api/activities [POST] /api/identify-face
[GET] /api/activities/{activity_id} [DELETE] /api/activities [POST] /api/power-off
[POST] /api/activities [POST] /api/posser [POST] /api/power-on
[POST] /api/activities/{activity_id} [POST] /api/audio/speech-to-text
[POST] /api/activities/{activity_id} [POST] /api/audio/text-to-speech

FIGURE IV.11 – Endpoints REST exposés à l'application mobile

```
PS C:\Users\l\Desktop\o\PFE\Backend + application mobile> curl.exe -X GET "http://127.0.0.1:8000/api/users" -H
"accept: application/json"
[{"id":"98a327fd-0ece-4afc-8b06-5a6499a9ce04","nom":"salah","image":"https://jynducbyosfpdetdomga.supabase.co/
storage/v1/object/public/photos_utilisateurs/s1.jpg"}, {"id":"d58ff93a-26d1-4785-867d-4934351cb4e2","nom":"sala
h","image":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/s2.jpg"}, {"i
d":"798bd831-0837-4c6c-93a1-f9654f22d074","nom":"salah","image":"https://jynducbyosfpdetdomga.supabase.co/stor
age/v1/object/public/photos_utilisateurs/s3.jpg"}, {"id":"ec7abfae-1460-473e-a5ab-c7dd65f091ea","nom":"salah","
image":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/s4.jpg"}, {"id":"2
a6df721-a61d-42e7-9ee3-f0a9e9acf756","nom":"salah","image":"https://jynducbyosfpdetdomga.supabase.co/storage/
v1/object/public/photos_utilisateurs/s5.jpg"}, {"id":"77af3963-e661-423f-8b48-5a70f79cf668","nom":"salah","imag
e":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/s6.jpg"}, {"id":"b788
4803-0039-474f-9c99-eb44d7a07063","nom":"salah","image":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/o
bject/public/photos_utilisateurs/s7.jpg"}, {"id":"0c8f6a3c-8a3b-45e8-ac7e-191c1ee861bd","nom":"oussema","image"
:"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/o1.jpg"}, {"id":"ac2884
e6-b761-405a-a2a9-93f4822c52e5","nom":"oussema","image":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/o
bject/public/photos_utilisateurs/o2.jpg"}, {"id":"6360315d-0c7d-4194-a518-393018d183e7","nom":"oussema","image"
:"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/o3.jpg"}, {"id":"e2e5ba
d9-2b00-42c6-b59d-392cf9c10673","nom":"oussema","image":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/o
bject/public/photos_utilisateurs/o4.jpg"}, {"id":"de605ab3-4d9c-4aac-b26e-de47c141c22a","nom":"oussema","image"
:"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/o5.jpg"}, {"id":"51b91c
f9-8512-42d7-84e2-efe9d043bef5","nom":"oussema","image":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/o
bject/public/photos_utilisateurs/o6.jpg"}, {"id":"38e05d5f-149f-444f-874e-9ede96e85696","nom":"oussema","image"
:"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/o7.jpg"}, {"id":"912fb4
8b-dc88-4314-911d-e5896de7f939","nom":"oussema","image":"https://jynducbyosfpdetdomga.supabase.co/storage/v1/o
bject/public/photos_utilisateurs/o8.jpg"}, {"id":"8a0deca6-72fe-48ce-a2af-2802c6cc90db","nom":"oussema","image"
:"https://jynducbyosfpdetdomga.supabase.co/storage/v1/object/public/photos_utilisateurs/o9.jpg"}]
PS C:\Users\l\Desktop\o\PFE\Backend + application mobile> curl.exe -X GET "http://127.0.0.1:8000/api/agendas"
-H "accept: application/json"
[{"id":1,"titre":"aaaa","note":"aaaa","etat":true,"contenu":"aaaa","date_modification":"2026-04-12T16:37:12.74
2374+00:00"}]
PS C:\Users\l\Desktop\o\PFE\Backend + application mobile> curl.exe -X POST "http://127.0.0.1:8000/api/power-on"
-H "accept: application/json"
{"status":"power_on","etat":1}
PS C:\Users\l\Desktop\o\PFE\Backend + application mobile> curl.exe -X GET "http://127.0.0.1:8000/test"
{"message":"Test OK"}
```

FIGURE IV.12 – Exécution de quelques endpoints (tests)

TABLE IV.2 – Endpoints exposés à l’application mobile (à compléter)

Endpoint	Méthode	Description

IV.4.3 Communication avec la base de données

La couche de persistance repose sur **PostgreSQL** hébergé sur **Supabase** (interface d’administration, SQL, gestion des accès). Le Distributeur y accède via **SQLAlchemy** (ORM) et **asynccpg** (asynchrone), selon la chaîne : *API REST* → *service* → *repository* → *PostgreSQL*.



FIGURE IV.13 – Interface Supabase — administration PostgreSQL

IV.4.3.1 Modèle relationnel et rôle des tables

Le modèle couvre les dimensions conversationnelles, contextuelles et organisationnelles. Principales tables :

- **conversation** (**id**, **question**, **reponce**, **date**, **type_de_question**, **personne**) : archive l’ensemble des conversations entre le robot et l’humain.
- **historique** (**id**, **date**, **question**, **reponce**, **type_de_question**) : conserve les 5 derniers messages pour la mémoire contextuelle immédiate.
- **information_personnel** (**id**, **question**, **reponce**, **date**, **acteur**, **type_de_question**) : stocke les informations personnelles liées à l’humain ou au robot.
- **note** (**id**, **note**, **etat**) : enregistre les rendez-vous et dates importantes de l’utilisateur.
- **setting** (**id**, **name**, **sexe**, **date**, **motdepasse**, **etat**, **caractere**, **langue**) : centralise l’identité et les paramètres généraux de KODA.
- **utilisateur** (**id**, **nom**, **image_url**) : référence les personnes connues par KODA avec leur nom et leur image.

- agenda (**id, titre, note, etat, contenu, date_modification**) : enregistre les éléments d’agenda saisis depuis l’application mobile.
- activity (**id, titre, description, etat, date, createdat**) : stocke les activités de l’utilisateur provenant de l’application mobile.
- accompagnement (**id, interets, synthese, point_cles, conseils, acteur**) : conserve l’analyse quotidienne consolidée pour chaque personne connue.

Le détail des relations entre tables est donné par la figure ?? (§ ??).

IV.4.4 Communication avec le workflow n8n

Le moteur de workflow **n8n** joue le rôle d’orchestrateur cognitif du système : il reçoit les requêtes, applique la logique de traitement et renvoie une réponse structurée au backend. Dans notre architecture, la communication entre Python et n8n est fondée sur un échange HTTP de type **requête/réponse** via webhook.

Rôle de cette communication

L’objectif principal est de déléguer à n8n la logique conversationnelle et décisionnelle, tout en conservant dans le backend Python les fonctions techniques (sécurité, accès base de données, services matériels). Cette séparation permet de modifier rapidement le comportement métier dans n8n sans impacter la couche d’exposition API.

Flux détaillé : de la requête à la réponse

Le scénario standard suit les étapes suivantes :

1. le backend récupère le **nom de l'utilisateur** (ou son identifiant) et la **question** formulée ;
2. il construit un payload JSON normalisé (ex. : {"name": "...", "question": "..."});
3. ce payload est envoyé au webhook n8n via une requête HTTP POST ;
4. n8n exécute le workflow correspondant : enrichissement du contexte, appels de services, règles de décision et génération de réponse ;
5. n8n retourne un objet de sortie contenant la **réponse finale** ;
6. le backend valide le format, journalise l’échange et renvoie la réponse au robot ou à l’application cliente.

Sur le plan qualité, cette interface inclut la gestion des *timeouts*, le contrôle des erreurs de webhook et la validation du schéma de réponse pour garantir la robustesse en exploitation.




FIGURE IV.14 – Communication avec n8n — exemple de payload en entrée de webhook

IV.5 Problèmes Rencontrés et Solutions Apportées

Le développement du backend a été ponctué de plusieurs défis techniques significatifs. Le tableau IV.3 en présente les principaux, accompagnés des solutions retenues.

TABLE IV.3 – Problèmes techniques rencontrés et solutions apportées

Problème rencontré	Impact	Solution adoptée
Latence élevée de la reconnaissance faciale sous charge	Blocage du thread principal FastAPI	Utilisation de <code>run_in_executor</code> pour déléguer le traitement au <code>ThreadPoolExecutor</code>
Déconnexions intempestives du WebSocket robot	Perte de commandes, état incohérent	Reconnexion automatique avec <i>backoff</i> exponentiel
Conflits de concurrence sur la base de données	Doublons de sessions et d'événements	Transactions atomiques et <code>SELECT FOR UPDATE</code>
Taille des encodages faciaux (128 flottants / profil)	Comparaisons massives lentes	Indexation vectorielle et cache Redis pour les encodages fréquents
Quota Azure STT dépassé lors des tests intensifs	Interruption du service vocal	Système de quota local et <i>fallback</i> Whisper (OpenAI)

Un défi transversal a concerné la gestion des dépendances circulaires entre modules dans une architecture Clean. Python, contrairement à Java, n'impose pas nativement l'inversion de

dépendances, ce qui peut conduire à des couplages non voulus. Ce problème a été résolu par l'utilisation systématique d'interfaces (classes abstraites Python) et d'un conteneur d'injection de dépendances (`dependency_injector`).

IV.6 Conclusion

Le Cycle 2 a permis de concevoir, de développer et de valider le composant le plus structurant de notre écosystème : le Distributeur de Services. Ce backend, développé en Python avec FastAPI et organisé selon les principes de la Clean Architecture, assure la totalité des communications entre les différents acteurs du système avec rigueur et fiabilité.

Les choix technologiques ont été justifiés par des critères objectifs : la richesse de l'écosystème Python pour l'IA, les performances asynchrones de FastAPI, et la flexibilité de la Clean Architecture pour absorber les évolutions futures. Les services développés — reconnaissance faciale, synthèse et transcription vocale, communication robot en temps réel, gestion de la base de données — ont tous été validés par des campagnes de tests rigoureuses.

Ce composant constitue désormais une fondation solide sur laquelle les cycles ultérieurs pourront s'appuyer pour étendre les fonctionnalités du système, notamment l'enrichissement des interactions conversationnelles et l'amélioration des capacités autonomes du robot.

Points clés du Cycle 2

- Modélisation (cas d'utilisation, classes, place dans l'architecture globale)
- Quatre communications : embarqué, mobile, base de données, workflow n8n
- Backend FastAPI + Clean Architecture ; services Azure, reconnaissance faciale
- Service de reconnaissance faciale avec 94,3 % de précision
- Intégration professionnelle des services Azure STT/TTS et de l'API Gemini

———— CHAPITRE V ————

CYCLE 3 : SYSTÈME EMBARQUÉ — PARTIE MATÉRIELLE

V.1 Introduction

Après le **Cycle 1** (moteur de réflexion n8n) et le **Cycle 2** (Distributeur de Services), le **Cycle 3** porte sur le **corps matériel** de KODA : choix des composants, câblage, alimentation et validation physique du prototype.

Ce chapitre reste volontairement centré sur le **hardware** et les **concepts d'intégration**. Le logiciel embarqué (scripts Raspberry Pi, protocoles série, audio, caméra) fera l'objet du **Cycle 4**.

Nous présentons l'architecture globale, la **conception 3D du châssis** (Blender), chaque sous-système (contrôle, actionneurs, audio, vision, affichage), le schéma de câblage, puis une campagne de **tests unitaires par composant** suivie d'un **test d'intégration** complète de la plateforme.

Objectif du Cycle 3

Concevoir, assembler et valider la plateforme matérielle du robot KODA, intégrant mobilité, interaction vocale, vision et expression faciale, prête à accueillir la couche logicielle embarquée du Cycle 4.

V.2 Architecture Matérielle Globale

L'architecture matérielle de KODA repose sur une conception **biprocasseur** articulée autour de deux unités de traitement complémentaires :

- **Raspberry Pi 4 Model B** : unité centrale intelligente, responsable du traitement des flux audio et vidéo, de la communication réseau avec le backend, et du pilotage de l'écran d'expression faciale.
- **Arduino Uno + Shield L293D** : unité de commande temps réel, dédiée au contrôle des actionneurs (servomoteurs et moteurs DC), recevant ses instructions du Raspberry Pi via une liaison série USB.

Cette séparation est motivée par un principe d'ingénierie fondamental : le Raspberry Pi, fonctionnant sous un système d'exploitation Linux, n'offre pas de garanties temps réel strictes pour le pilotage de signaux PWM. L'Arduino, en revanche, exécute un programme monotâche cadencé à 16 MHz, garantissant une précision temporelle adaptée au contrôle moteur.

Le tableau V.1 synthétise l'ensemble des composants matériels du robot.

TABLE V.1 – Inventaire des composants matériels de KODA

Catégorie	Composant	Rôle
Unité centrale	Raspberry Pi 4 Model B	Traitement IA, réseau, audio/vidéo
Commande moteur	Arduino Uno + Shield L293D	Pilotage PWM des actionneurs
Mobilité	2 moteurs DC (M1, M3)	Déplacement du robot (traction différentielle)
Articulations	3 servomoteurs (S1, S2, S3)	Bras droit, bras gauche ; S3 = écran Nextion
Entrée audio	ReSpeaker 4-Mic Array USB	Capture vocale + direction de la voix
Sortie audio	Jack + PAM8403 + HP ; Bluetooth	Restitution filaire ou sans fil
Vision	Caméra Raspberry Pi (CSI)	Acquisition d'images pour identification
Affichage	Nextion NX4832T035_011 (3,5")	Visage animé du robot
Alimentation Pi	Power Bank 5V / 3A	Alimentation du Raspberry Pi
Alimentation moteurs	3 × piles 3,7V	Alimentation du Shield L293D

V.3 Conception mécanique et châssis 3D (Blender)

Au-delà du câblage électronique, KODA repose sur un **habillage mécanique** imprimé en 3D, conçu sous **Blender**. Le point de départ n'était pas une création entièrement *from scratch*, mais un **modèle 3D existant** (humanoid simplifié) que nous avons dû **adapter** au prototype réel : découpe des volumes, redimensionnement des pièces, ajout d'ouvertures manquantes (logement écran Nextion, passage caméra sur le torse, fixation des bras) et harmonisation avec la base à chenilles.

Cette étape a constitué un **vrai défi** du Cycle 3 : chaque modification impacte l'encombrement interne (câbles, Raspberry Pi, batterie) et la cohérence visuelle du robot. La figure V.1 illustre la vue éclatée des pièces modélisées ; la figure V.2 montre le résultat physique après impression et assemblage.

Choix mécaniques retenus sur le prototype :

- **Caméra** : fixée sur le **torse** (corps), face avant, indépendante du servo S3.
- **Écran Nextion** : intégré dans la **tête**, entraîné par le servo S3 (rotation du visage animé seulement).
- **Base** : châssis à chenilles pour la mobilité (moteurs M1/M3).




FIGURE V.1 – Conception 3D du châssis KODA sous Blender (vue éclatée des pièces)

V.4 Description Détaillée des Composants

V.4.1 Unité Centrale : Raspberry Pi 4 Model B

Le **Raspberry Pi 4 Model B** constitue le cœur du robot KODA. Il s'agit d'un ordinateur monocarte (SBC — *Single Board Computer*) basé sur un processeur ARM Cortex-A72 quadricœur cadencé à 1,5 GHz, équipé de 4 Go de mémoire RAM LPDDR4.

Dans l'architecture de KODA, le Raspberry Pi assure les fonctions suivantes :

- **Communication réseau** : connexion Wi-Fi au backend (Distributeur de Services) pour l'échange de données avec les workflows n8n et la base de données.
- **Traitement audio** : ReSpeaker en entrée (USB) ; sortie soit via le **jack 3,5 mm** et l'amplificateur PAM8403, soit via **Bluetooth** vers un haut-parleur externe.
- **Traitement vidéo** : acquisition d'images via la caméra pour la reconnaissance faciale.
- **Pilotage de l'écran Nextion** : communication série UART pour l'affichage des expressions faciales.
- **Commande de l'Arduino** : envoi d'instructions de mouvement via la liaison série USB.

V.4.2 Unité de Commande Moteur : Arduino Uno + Shield L293D

L'**Arduino Uno** est une carte de développement à microcontrôleur ATmega328P, cadencé à 16 MHz. Il est couplé au **Shield L293D**, un circuit intégré de pilotage moteur (*motor driver*) qui permet de contrôler simultanément jusqu'à 4 moteurs DC et 2 servomoteurs.

Dans KODA, l'Arduino reçoit ses instructions du Raspberry Pi via une **liaison série USB** et



FIGURE V.2 – Prototype physique KODA après impression 3D et montage

TABLE V.2 – Spécifications techniques du Raspberry Pi 4 Model B

Caractéristique	Valeur
Processeur	Broadcom BCM2711, Cortex-A72 quad-core @ 1,5 GHz
Mémoire	4 Go LPDDR4
Connectivité	Wi-Fi 802.11ac, Bluetooth 5.0
Ports USB	2 × USB 3.0 + 2 × USB 2.0
Sortie audio	Jack 3,5 mm stéréo
Interface caméra	Port CSI (Camera Serial Interface)
GPIO	40 broches (dont UART, I2C, SPI)
Alimentation	5V / 3A via USB-C

pilote :

- **2 moteurs DC** (bornes **M1** et **M3** du shield) : déplacement par traction différentielle.
- **3 servomoteurs** :
 - **S1** : bras droit
 - **S2** : bras gauche
 - **S3** : tête / cou (rotation de l'écran Nextion uniquement)

Le Shield L293D est alimenté indépendamment par **3 piles lithium de 3,7 V** connectées en série, fournissant une tension nominale d'environ 11,1 V nécessaire au fonctionnement des moteurs DC sous charge.

V.4.3 Système d'Actionneurs

V.4.3.1 Moteurs DC — Mobilité

Les deux moteurs à courant continu assurent la **locomotion** du robot par un système de **traction différentielle** : en faisant varier indépendamment la vitesse et le sens de rotation de chaque moteur, le robot peut avancer, reculer, tourner à gauche ou à droite. Ce principe simple et éprouvé est largement utilisé en robotique mobile (figure V.3).

V.4.3.2 Servomoteurs — Articulations

Les trois servomoteurs offrent à KODA des capacités d'**expression corporelle** :

- **Servomoteur S1 (bras droit) et S2 (bras gauche)** : permettent de simuler des gestes d'accueil, de salutation ou d'indication directionnelle.
- **Servomoteur S3 (tête / cou)** : oriente uniquement l'**écran Nextion** (visage animé). La **caméra** est fixée sur le **châssis** (corps) du robot et ne suit pas ce mouvement.




FIGURE V.3 – Principe de traction différentielle — moteurs M1 et M3

V.4.4 Système Audio

V.4.4.1 Entrée Audio : ReSpeaker 4-Mic Array USB

Le **ReSpeaker 4-Mic Array** de Seeed Studio est un périphérique USB intégrant quatre microphones MEMS disposés en configuration circulaire. Cette disposition permet deux fonctionnalités essentielles :

- **Capture vocale omnidirectionnelle** : enregistrement de la voix de l'utilisateur quelle que soit sa position autour du robot.
- **Détection de la Direction d'Arrivée (DOA — *Direction of Arrival*)** : identification de l'angle d'où provient la voix. Le robot **pivote sur place** grâce aux **deux moteurs DC** (M1, M3) pour s'orienter vers l'interlocuteur, puis la **caméra** (fixée sur le corps) permet la détection du visage (figure V.4).

Le ReSpeaker est connecté au Raspberry Pi via un **port USB** et est reconnu comme un périphérique audio standard sous Linux.

V.4.4.2 Sortie Audio : double chaîne (jack filaire et Bluetooth)

KODA dispose de **deux modes de restitution** de la parole, tous deux pilotés depuis le Raspberry Pi :

- **Chaîne filaire** : sortie **jack 3,5 mm** du Pi → amplificateur **PAM8403** → deux haut-parleurs (gauche / droite). Solution compacte, intégrée au châssis.
- **Chaîne sans fil** : le Bluetooth intégré du Raspberry Pi 4 peut envoyer le flux audio vers un

Direction of arrival (DOA) — KODA




FIGURE V.4 – Enchaînement conceptuel : DOA (micro) → rotation du robot (M1, M3) → caméra (torse)

haut-parleur Bluetooth (appairage classique). Utile pour les essais ou une sortie plus puissante sans modifier le câblage jack.

Le choix entre les deux dépend du contexte de démonstration ; la couche logicielle (Cycle 4) sélectionnera la carte audio ALSA appropriée.

V.4.5 Système de Vision : Caméra Raspberry Pi

La **caméra officielle Raspberry Pi** est connectée via le port **CSI** (nappe dédiée). Elle fournit les images nécessaires à l'**identification visuelle** des utilisateurs.

Au niveau matériel, seule la **qualité de capture** (netteté, éclairage, cadrage) est concernée dans ce cycle. L'envoi des images vers le serveur distant et le traitement logiciel seront détaillés au **Cycle 4**.

V.4.6 Interface d'Expression Faciale : Nextion NX4832T035_011

L'écran **Nextion NX4832T035_011** (3,5 pouces) intègre son propre microcontrôleur : le Raspberry Pi n'affiche pas des pixels en temps réel, mais envoie des **commandes série** pour changer de page ou d'expression (sourire, surprise, écoute, etc.) déjà stockées dans la mémoire de l'écran.

Alimentation et liaison (câblage retenu sur le prototype) :

- **5 V** et **GND** du Nextion reliés au **5 V** et **GND** du GPIO du Raspberry Pi (masse commune).
- **RX** du Nextion (fil jaune) → broche **8** du Pi (**GPIO 14**, ligne **TX** du Pi).
- **TX** du Nextion (fil bleu) → broche **10** du Pi (**GPIO 15**, ligne **RX** du Pi).

Ce câblage UART permet au Pi d'animer le **visage** de KODA sans surcharger le bus USB, tout

en gardant une interface visuelle dédiée à l'interaction humaine.

V.4.7 Système d’Alimentation

Le robot KODA dispose de **deux sources d'alimentation indépendantes**, séparant volontairement la partie logique de la partie motrice :

TABLE V.3 – Architecture d'alimentation de KODA

Source	Caractéristiques	Composants alimentés
Power Bank	5V / 3A, USB-C	Raspberry Pi 4 (et par extension : ReSpeaker, caméra, écran Nextion via GPIO)
3× piles Li-ion	3,7V chacune (11,1V total)	Shield L293D, moteurs DC, servo-moteurs

Cette séparation protège le Raspberry Pi contre les perturbations électromagnétiques et les chutes de tension provoquées par les appels de courant des moteurs.

V.5 Schéma de Câblage Global

La figure V.5 présente le **schéma de montage** du prototype : vue type *Fritzing*, avec l'ensemble des connexions entre Raspberry Pi, Arduino, capteurs, actionneurs et alimentations.




FIGURE V.5 – Schéma de montage matériel de KODA — style Fritzing (Cycle 3)

Le tableau V.4 récapitule les connexions pour la rédaction et la maintenance du prototype.

TABLE V.4 – Récapitulatif des connexions entre composants

Composant	Connecté à	Interface	Détail
Arduino Uno	Raspberry Pi	USB	Commandes moteur (série)
ReSpeaker 4-Mic	Raspberry Pi	USB	Entrée audio + DOA
PAM8403 + HP L/R	Raspberry Pi	Jack 3,5 mm	Sortie filaire
HP Bluetooth	Raspberry Pi	Bluetooth	Sortie sans fil (option)
Caméra Pi	Raspberry Pi	CSI	Nappe caméra
Nextion NX4832T035_011	Raspberry Pi	UART alim +	5V/GND GPIO ; RX → pin 8 ; TX → pin 10
Moteurs DC M1, M3	Shield L293D	Bornes M1, M3	Traction différentielle
Servos S1, S2, S3	Shield L293D	Servo 1, 2, 3	Bras D/G ; S3 = Nextion
Power Bank 5V/3A	Raspberry Pi	USB-C	Alimentation logique
3 × piles 3,7V (série)	Shield L293D	Vin	Alimentation motrice

V.6 Assemblage et points d'attention

L'intégration physique a mis en évidence quelques **contraintes** récurrentes, sans entrer dans le détail logiciel (Cycle 4) :

- **Séparation des alimentations** : éviter de nourrir les moteurs depuis le 5 V du Pi ; les perturbations PWM peuvent provoquer des réinitialisations ou du bruit sur l'audio.
- **UART Nextion** : respecter le croisement TX/RX (fil RX de l'écran vers TX du Pi) et une masse commune stable.
- **USB multiples** : ReSpeaker, Arduino et alimentation compétent pour les ports USB du Pi ; une alimentation 5 V/3 A fiable (power bank) est indispensable.
- **Encombrement mécanique** : la nappe CSI (caméra sur le corps) et les câbles des servos (dont S3 pour le Nextion) doivent rester libres de frottement lors des mouvements articulés.

V.7 Validation matérielle — tests par composant

Chaque sous-système a été validé **individuellement** avant le test global (contrôle visuel ou fonctionnel, sans détailler les scripts). Le tableau V.5 ci-dessous synthétise cette démarche.

TABLE V.5 – Tests unitaires par composant (Cycle 3)

Composant	Procédure (concept)	Critère OK
Power Bank + Pi	Mise sous tension, boot Raspberry Pi OS	LED activité, pas de brown-out
ReSpeaker USB	Enregistrement court, niveau sonore	Signal audible, périphérique reconnu
Sortie jack + PAM8403	Lecture d'un son test sur les HP	Son clair L/R
Sortie Bluetooth	Appairage HP BT, lecture test	Son sur HP externe
Caméra CSI	Capture d'une image fixe	Image nette, pas de bandes
Nextion UART	Changement de page ou d'expression	Affichage réactif
Arduino + USB	Envoi d'une commande simple (moniteur série)	Réponse attendue
Moteurs M1, M3	Avancer, reculer, pivoter	Roues cohérentes
Servos S1, S2, S3	Balayage angle min-max	Mouvement fluide, sans à-coups
Alim. 3 piles (série)	Charge moteurs à vide	Tension stable sur Vin

V.7.1 Test d'intégration matérielle

Le **test complet** consiste à alimenter l'ensemble, vérifier que le Pi détecte simultanément micro, caméra et écran, que l'Arduino répond toujours sur USB, et qu'un scénario court combine : capture vocale, mouvement des servos, rotation des roues, changement d'expression Nextion, sans coupure d'alimentation ni conflit USB. Ce test valide la **plateforme prête pour le Cycle 4** (logiciel embarqué et liaison réseau avec le backend).

V.8 Conclusion

Ce chapitre a présenté l'intégralité de la plateforme matérielle du robot KODA. L'architecture biprocesseur retenue — Raspberry Pi pour l'intelligence et l'Arduino pour le contrôle moteur — garantit à la fois la puissance de calcul nécessaire aux traitements IA et la précision temporelle requise pour le pilotage des actionneurs.

Chaque composant a été sélectionné et intégré pour répondre aux exigences fonctionnelles définies au chapitre II : mobilité, interaction vocale bidirectionnelle, reconnaissance visuelle et expression émotionnelle. La plateforme matérielle est désormais prête à accueillir la couche logicielle embarquée, objet du **Cycle 4** présenté dans le chapitre suivant.

Points clés du Cycle 3

- Architecture biprocesseur : Raspberry Pi 4 + Arduino Uno / L293D
- 5 actionneurs : M1/M3 (DC) + S1/S2 (bras) + S3 (Nextion)
- Audio : ReSpeaker (entrée) ; sortie jack/PAM8403 ou Bluetooth
- Nextion NX4832T035_011 (UART GPIO 8/10, alim. 5 V Pi)
- Tests unitaires puis intégration ; logiciel au Cycle 4